République Tunisienne
Ministère de l'Enseignement Supérieur
et de la Recherche Scientifique

Université de Sfax

École nationale d'électronique
et des télécommunications de Sfax

Ingénieur en :
Génie Systèmes Électroniques
et Communication

Option :
Systèmes Embarqués

Rapport de stage

présenté à

L'École Nationale d'Électronique et des Télécommunications de Sfax

en vue de l'obtention du

Diplôme National d'Ingénieur en :
Génie Systèmes Électroniques et Communication

Option :
Systèmes Embarqués

par

AMIR HACHICHA

R et D — Qualification fiable des pièces repeintes vs peinture d'origine sur véhicule par vision artificielle

M.	**Wassim Mallouli**	*Encadrant*

Année Universitaire : 2026-2027

DEDICATION

À mes très chers parents, qui n'ont cessé de me soutenir, de m'encourager et de croire en moi tout au long de mon parcours académique. Vos sacrifices et votre amour inconditionnel sont la source de ma persévérance.

À ma chère mère et à mon cher père.

À mes amis et camarades de promotion à l'ENET'COM, avec qui j'ai partagé ces années de formation enrichissantes. Nos échanges et notre entraide ont rendu cette expérience inoubliable.

À mes amis..

À À tous ceux qui, de près ou de loin, ont contribué à ma réussite et m'ont encouragé à persévérer.

À **vous tous**,

Je dédie ce travail.

Amir HACHICHA

REMERCIEMENT

Au terme de ce stage, je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, directement ou indirectement, à sa réalisation et au bon déroulement de cette expérience.

Je remercie tout particulièrement MALLOULINOVA pour m'avoir accueilli au sein de son environnement professionnel et m'avoir donné l'opportunité de mettre en pratique mes connaissances dans le domaine de l'intelligence artificielle, de la vision par ordinateur et du développement logiciel.

Je tiens à remercier mon encadrant ainsi que l'ensemble de l'équipe de MALLOULINOVA pour leur disponibilité, leurs conseils et leur accompagnement tout au long de ce stage. Leurs remarques et leurs orientations m'ont permis de mieux comprendre les exigences d'un projet appliqué et de progresser dans ma démarche technique et scientifique.

Je remercie également les personnes et les professionnels qui ont contribué à la collecte des données nécessaires à l'étude expérimentale menée dans le cadre du projet MALLOULIAUTO. Leur collaboration a permis de constituer les premières données utilisées pour l'étude de la classification des surfaces automobiles entre peinture d'origine et peinture repeinte.

J'adresse également mes remerciements à mes enseignants et à l'équipe pédagogique de mon établissement pour la formation et les connaissances acquises au cours de mon parcours d'ingénieur, qui ont constitué une base essentielle pour la réalisation de ce stage.

À toutes ces personnes, j'adresse mes sincères remerciements.

TABLE DES MATIÈRES

LISTE DES FIGURES vi

LISTE DES TABLEAUX vii

INTRODUCTION GÉNÉRALE viii

1 CADRE GÉNÉRAL DU PROJET 2

1.1 INTRODUCTION 3

1.2 PRÉSENTATION GÉNÉRALE DE LA SOCIÉTÉ 3

1.2.1 PRÉSENTATION DE L'ENTREPRISE D'ACCUEIL 3

1.2.2 PRÉSENTATION DE LA PLATEFORME MALLOULIAUTO 3

1.3 ÉTUDE DE L'EXISTANT 4

1.3.1 INSPECTION VISUELLE DES SURFACES AUTOMOBILES 4

1.3.2 TECHNIQUES INSTRUMENTALES 4

1.3.3 VISION ARTIFICIELLE ET DEEP LEARNING 5

1.4 OBJECTIFS DU STAGE 6

1.5 COMPARAISON DES SOLUTIONS 7

1.6 CHOIX ET SOLUTION RETENUE 7

1.7 MÉTHODOLOGIE ADOPTÉE 8

1.8 CONCLUSION 9

2 MÉTHODOLOGIE ET PIPELINE IA 10

2.1 INTRODUCTION 11

2.2 PROTOCOLE D'ACQUISITION 11

2.2.1 ENVIRONNEMENTS DE COLLECTE 11

2.2.2 DISPOSITIF EXPÉRIMENTAL 12

2.2.3 PARAMÈTRES ET PROCÉDURE DE CAPTURE 14

2.3 CONSTITUTION DU DATASET 15

2.3.1 ORGANISATION DES DONNÉES 15

2.3.2 RÉPARTITION DES CLASSES ET DES SESSIONS 16
2.3.3 SÉPARATION TRAIN / VALIDATION / TEST 16
2.3.4 CONTRÔLE DES DOUBLONS ET DES FUITES 17
2.4 PRÉPARATION DES IMAGES 18
2.5 ARCHITECTURE ET STRATÉGIE D'ENTRAÎNEMENT 20
2.5.1 VUE D'ENSEMBLE 20
2.5.2 PIPELINE DE TRAITEMENT D'IMAGE 21
2.5.3 ARCHITECTURE EFFICIENTNET-B0 22
2.5.4 ADAPTATION À LA CLASSIFICATION BINAIRE 24
2.5.5 GESTION DU DÉSÉQUILIBRE DES CLASSES 24
2.5.6 PHASE 1 : BACKBONE GELÉ 24
2.5.7 PHASE 2 : FINE-TUNING LIMITÉ 25
2.6 INTÉGRATION DANS LA PLATEFORME 25
2.6.1 COMMUNICATION ENTRE LE FRONTEND ET LE BACKEND . . 25
2.6.2 TRAITEMENT DE LA REQUÊTE ET RETOUR DU RÉSULTAT . . 26
2.7 CONCLUSION 27

3 RÉSULTATS ET ANALYSE 28
3.1 INTRODUCTION 29
3.2 RÉSULTATS DE L'ENTRAÎNEMENT 29
3.2.1 PERFORMANCE DU MODÈLE 29
3.2.2 COMPARAISON DES DEUX PHASES D'ENTRAÎNEMENT 31
3.3 ÉVALUATION DU MODÈLE 32
3.3.1 MATRICE DE CONFUSION 32
3.3.2 INDICATEURS DE PERFORMANCE 33
3.3.3 COURBE ROC ET AUC 34
3.4 ANALYSE DES ERREURS 35
3.4.1 FAUX POSITIFS ET FAUX NÉGATIFS 35
3.4.2 INFLUENCE DES CONDITIONS DE CAPTURE 36
3.4.3 ARTEFACTS OPTIQUES OBSERVÉS 36
3.4.4 LIMITES LIÉES AU DATASET 37
3.5 GESTION DES PRÉDICTIONS INCERTAINES 37
3.5.1 NÉCESSITÉ D'UNE ZONE D'INCERTITUDE 37
3.5.2 PRINCIPE DE DÉCISION 38
3.5.3 INTÉRÊT POUR UNE UTILISATION EN INSPECTION 39
3.6 INTERFACE WEB DE DÉMONSTRATION 40

3.6.1 PRÉSENTATION DE L'INTERFACE 40
3.6.2 SÉLECTION ET PRÉVISUALISATION DE L'IMAGE 40
3.6.3 LANCEMENT DE L'ANALYSE 41
3.6.4 AFFICHAGE DU RÉSULTAT ET DE LA ZONE CENTRALE 42
3.7 DISCUSSION DES RÉSULTATS ET RECOMMANDATIONS 43
3.7.1 INTERPRÉTATION DES RÉSULTATS 43
3.7.2 APPORTS ET LIMITES DE L'APPROCHE 44
3.8 CONCLUSION 45

CONCLUSION GÉNÉRALE **46**

BIBLIOGRAPHIE **47**

ANNEXES **49**
A.1 Métadonnées 49
A.2 Configuration et évaluation du modèle 50
A.2.1 Configuration d'entraînement 50
A.2.2 Classification report 50

LISTE DES FIGURES

1.1 Vue d'ensemble des techniques instrumentales d'inspection de la pénétration. . 5
1.2 Détection des défauts de surface en atelier de peinture 6

2.1 Environnements professionnels de collecte 12
2.2 Dispositif Redmi Note 12 équipé du module Apexel 13
2.3 Exemple de microtexture observée sur une surface automobile 14
2.4 Organisation du dataset en Train, Validation et Test 15
2.5 Exemple de préparation d'une image avant l'inférence 19
2.6 Vue d'ensemble de l'architecture du système 21
2.7 pipeline général de traitement de l'image 22
2.8 ARCHITECTURE DU MODÈLE DE CLASSIFICATION 23

3.1 Évolution de la fonction de perte et de l'accuracy pendant les deux phases d'entraînement 30
3.2 Matrice de confusion sur le jeu de test 32
3.3 Courbe ROC pour la classe positive Repeint 34
3.4 Interface web avant le lancement de l'analyse 41
3.5 Affichage du verdict, des probabilités et de la zone centrale utilisée par le modèle 42

A.1 Métadonnées utilisées pour le dataset 49

LISTE DES TABLEAUX

1.1 Comparaison qualitative des solutions d'acquisition 7

2.1 Paramètres de capture utilisés 14
2.2 Répartition globale du dataset 16
2.3 Répartition des images par sous-ensemble 17

3.1 Comparaison qualitative des deux phases 31
3.2 Indicateurs de performance du modèle sur le jeu de test 33
3.3 Répartition des erreurs 35
4 Configuration d'entraînement du modèle 50
5 Classification report du modèle 50

INTRODUCTION GÉNÉRALE

Ces dernières années, les avancées de l'intelligence artificielle et de la vision par ordinateur ont ouvert de nouvelles perspectives dans le domaine de l'inspection visuelle industrielle. Dans le secteur automobile, l'analyse de l'état de la carrosserie constitue une étape importante pour l'expertise, l'assurance, la vente de véhicules d'occasion et le contrôle qualité. Parmi les besoins rencontrés figure la distinction entre une peinture d'origine et une peinture appliquée après réparation.

Cette distinction reste complexe, car une pièce repeinte ne présente pas nécessairement de défauts visibles à l'œil nu. Selon la qualité de la réparation, les différences peuvent se manifester par de faibles variations de texture, de brillance, de reflet ou de finition. L'expert humain s'appuie généralement sur plusieurs indices visuels ainsi que sur son expérience du domaine. L'automatisation de cette tâche constitue donc un défi, notamment lorsque la solution recherchée doit être mobile, rapide et accessible.

Dans ce contexte, le présent projet s'inscrit dans la plateforme MALLOULIAUTO, une solution dédiée à la certification et à l'inspection des véhicules d'occasion. Le stage porte sur l'étude de faisabilité d'un module permettant de qualifier automatiquement des surfaces automobiles selon deux classes : peinture d'origine et peinture repeinte. L'étude s'intéresse notamment à l'utilisation d'images acquises à courte distance à l'aide d'un smartphone associé à un dispositif optique portable.

L'objectif principal n'est pas de développer immédiatement un système industriel définitif, mais d'évaluer si les informations visuelles contenues dans les images acquises peuvent être exploitées par un modèle de Deep Learning pour distinguer les deux catégories étudiées. Le travail consiste ainsi à étudier les solutions existantes, définir un protocole d'acquisition, constituer

un dataset propriétaire pilote, entraîner un modèle de classification binaire, évaluer ses performances et réaliser une intégration expérimentale dans une interface web de démonstration.

Le rapport est organisé en trois chapitres. Le premier chapitre présente le cadre du projet, l'entreprise d'accueil, le besoin identifié ainsi que l'étude des solutions existantes. Il présente ensuite la comparaison des différentes approches et le choix de la solution retenue, ainsi que les objectifs, les contraintes et la méthodologie générale du stage.

Le deuxième chapitre décrit la mise en œuvre de la solution proposée. Il présente le protocole d'acquisition, la constitution du dataset, la préparation des images, l'architecture du système, la stratégie d'entraînement du modèle EfficientNet-B0 ainsi que son intégration expérimentale dans la plateforme.

Enfin, le troisième chapitre présente les résultats obtenus et leur évaluation. Il aborde les performances du modèle, l'analyse des erreurs, la gestion des prédictions incertaines, l'interface web de démonstration ainsi que la discussion des résultats et des limites de l'approche.

Chapitre

1

CADRE GÉNÉRAL DU PROJET

Sommaire

1.1 INTRODUCTION 3
1.2 PRÉSENTATION GÉNÉRALE DE LA SOCIÉTÉ 3
1.2.1 PRÉSENTATION DE L'ENTREPRISE D'ACCUEIL 3
1.2.2 PRÉSENTATION DE LA PLATEFORME MALLOULIAUTO 3
1.3 ÉTUDE DE L'EXISTANT 4
1.3.1 INSPECTION VISUELLE DES SURFACES AUTOMOBILES 4
1.3.2 TECHNIQUES INSTRUMENTALES 4
1.3.3 VISION ARTIFICIELLE ET DEEP LEARNING 5
1.4 OBJECTIFS DU STAGE 6
1.5 COMPARAISON DES SOLUTIONS 7
1.6 CHOIX ET SOLUTION RETENUE 7
1.7 MÉTHODOLOGIE ADOPTÉE 8
1.8 CONCLUSION 9

1.1 INTRODUCTION

Ce chapitre a pour objectif de présenter le cadre général dans lequel s'inscrit notre projet de stage réalisé au sein de la société MALLOULINOVA dans le contexte de la plateforme MALLOULIAUTO. Nous commençons par introduire l'entreprise d'accueil et la plateforme concernée. Ensuite, nous détaillons les principales solutions existantes pour l'inspection de la peinture automobile, notamment l'observation visuelle, les techniques instrumentales et les approches basées sur la vision artificielle. Cela nous permet d'effectuer une comparaison qualitative des solutions étudiées afin de justifier le choix d'une acquisition mobile. Enfin, nous présentons les objectifs, le périmètre, les contraintes ainsi que la méthodologie générale adoptée pour piloter le projet.

1.2 PRÉSENTATION GÉNÉRALE DE LA SOCIÉTÉ

1.2.1 PRÉSENTATION DE L'ENTREPRISE D'ACCUEIL

MALLOULINOVA est une entreprise tunisienne spécialisée dans le développement de solutions numériques appliquées au secteur automobile. Ses activités s'inscrivent dans une démarche d'amélioration de l'inspection et de la certification des véhicules d'occasion à travers l'exploitation de données techniques, d'images et de modèles d'intelligence artificielle. Le stage réalisé s'intègre dans cette orientation et porte sur l'étude d'une solution de vision artificielle destinée à analyser la texture des surfaces automobiles et à distinguer expérimentalement une peinture d'origine d'une peinture repeinte.

1.2.2 PRÉSENTATION DE LA PLATEFORME MALLOULIAUTO

MALLOULIAUTO est une startup et une solution développée dans le cadre de MALLOULINOVA. Elle vise à améliorer la certification et l'inspection des véhicules d'occasion en proposant des contrôles structurés et une meilleure traçabilité des informations collectées. La plateforme peut

être utilisée par différents acteurs du secteur automobile, notamment les assurances, les centres d'inspection, les entreprises de leasing, les sociétés de location et de gestion de flotte, les ateliers de carrosserie-peinture, les concessionnaires et les acteurs du remarketing. Dans le cadre de ce stage, une extension expérimentale de vision artificielle est étudiée afin d'analyser la texture des surfaces automobiles et de distinguer une peinture d'origine d'une peinture repeinte. Ce module constitue une aide à l'inspection ne remplace pas l'expertise humaine.

1.3 ÉTUDE DE L'EXISTANT

1.3.1 INSPECTION VISUELLE DES SURFACES AUTOMOBILES

L'inspection visuelle constitue l'une des premières étapes de l'évaluation d'un véhicule. Elle permet d'observer l'état général de la carrosserie, la présence de rayures, de différences de teinte, de défauts de finition ou de variations de brillance. Cette méthode reste cependant dépendante de l'éclairage, de l'angle d'observation et de l'expérience de l'inspecteur. Une réparation de bonne qualité peut être difficile à distinguer d'une peinture d'origine à l'œil nu. L'observation visuelle fournit donc une première indication, mais elle ne garantit pas toujours une conclusion fiable.

1.3.2 TECHNIQUES INSTRUMENTALES

Les techniques instrumentales permettent d'obtenir des mesures plus objectives, mais elles nécessitent généralement du matériel spécialisé. La mesure d'épaisseur de peinture permet d'identifier une différence d'épaisseur entre plusieurs zones d'une carrosserie. La spectrophotométrie fournit des mesures colorimétriques précises, tandis qu'une charte ColorChecker peut être utilisée pour calibrer une caméra. La déflectométrie permet d'analyser la déformation de motifs réfléchis par la surface et d'étudier des phénomènes tels que la peau d'orange ou la distorsion des reflets. Ces solutions sont pertinentes dans un contexte industriel ou de laboratoire, mais leur coût, leur complexité et leur faible portabilité peuvent limiter leur utilisation dans une application mobile destinée au terrain.

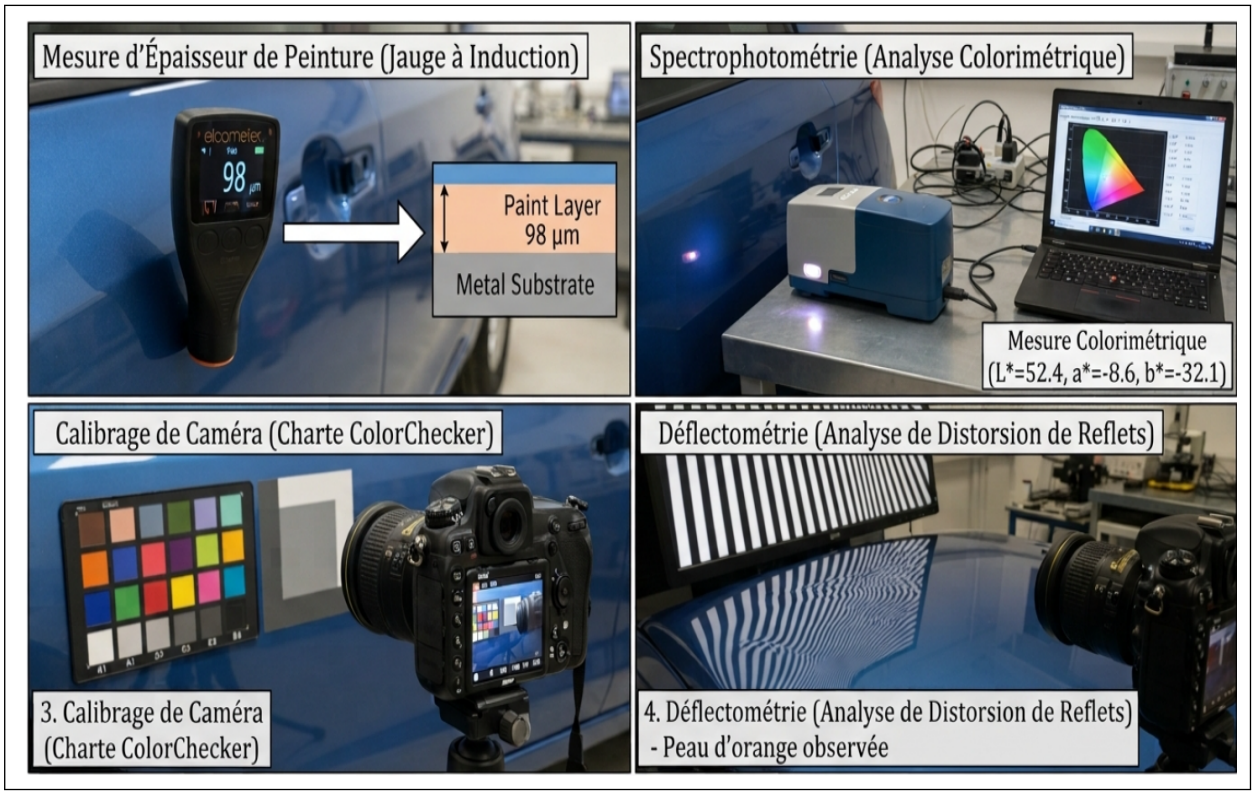


FIGURE 1.1 – Vue d'ensemble des techniques instrumentales d'inspection de la pénétration.

1.3.3 VISION ARTIFICIELLE ET DEEP LEARNING

La vision artificielle permet d'analyser automatiquement les images et d'extraire des caractéristiques liées à la couleur, à la texture, aux contours et aux défauts de surface. Les réseaux de neurones convolutionnels sont particulièrement adaptés à la classification d'images, car ils apprennent automatiquement des représentations visuelles à partir des données.

Le Transfer Learning permet de réutiliser un modèle pré-entraîné sur une base d'images générale, puis de l'adapter à une nouvelle tâche. Cette approche est pertinente dans le cadre du stage, car le dataset propriétaire est encore limité.

L'acquisition macro peut renforcer le signal disponible pour le modèle en rendant visibles des variations de texture difficiles à observer sur une image prise à distance normale.



FIGURE 1.2 – Détection des défauts de surface en atelier de peinture

1.4 OBJECTIFS DU STAGE

L'objectif principal du stage est d'étudier la faisabilité d'une approche basée sur la vision artificielle permettant de distinguer expérimentalement les surfaces automobiles d'origine des surfaces repeintes à partir d'images macro.

Les objectifs spécifiques sont :

- étudier les principales solutions d'inspection de peinture automobile ;
- analyser les possibilités offertes par l'acquisition macro ;
- sélectionner un dispositif adapté aux contraintes du stage ;
- définir un protocole d'acquisition ;
- constituer un dataset propriétaire pilote ;
- préparer les images pour l'apprentissage ;
- entraîner un modèle EfficientNet-B0 ;
- évaluer ses performances ;
- analyser les erreurs obtenues ;
- intégrer le modèle dans une interface web de démonstration.

L'objectif du stage est de réaliser une étude exploratoire à partir d'un dataset propriétaire pilote, afin d'évaluer la faisabilité d'une classification binaire des surfaces automobiles. Le travail ne vise pas encore la validation industrielle d'un système complet.

1.5 COMPARAISON DES SOLUTIONS

Les différentes solutions étudiées sont comparées selon plusieurs critères, comme présentés dans le tableau 1.1.

TABLE 1.1 – Comparaison qualitative des solutions d'acquisition

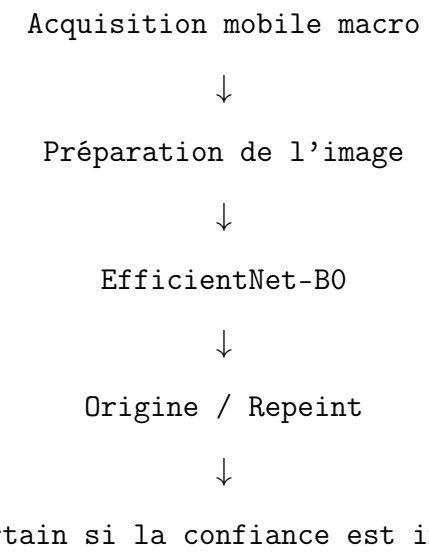
Solution	**Coût**	**Portabilité**	**Signal texture**	**Équipement spécialisé**	**Intégration mobile**
Smartphone standard	Faible	Très élevée	Limité	Non	Très facile
Smartphone + module macro	Faible à moyen	Élevée	Potentiellement élevé	Faible	Facile
LED + CPL séparés	Moyen	Moyenne	Amélioré	Accessoires multiples	Moyenne
Spectrophotomètre	Élevé	Moyenne	Principalement colorimétrique	Oui	Limitée
ColorChecker	Moyen	Moyenne	Calibration couleur	Oui	Moyenne
Déflectométrie	Très élevé	Faible	Très riche	Oui	Difficile

Cette comparaison est qualitative. Elle sert à orienter le choix du dispositif, mais ne constitue pas un benchmark exhaustif de toutes les solutions disponibles.

1.6 CHOIX ET SOLUTION RETENUE

L'étude des différentes solutions montre qu'une configuration mobile basée sur un smartphone associé à un module macro constitue un compromis adapté aux contraintes du stage. Cette configuration permet de réaliser des acquisitions rapprochées tout en conservant une solution légère, portable et peu coûteuse.

La solution retenue repose sur la chaîne suivante :



Cette solution est choisie pour sa compatibilité avec une utilisation terrain, sa simplicité de déploiement et sa possibilité d'intégration future dans une plateforme d'inspection automobile.

Les détails du dispositif utilisé, des paramètres de capture, du dataset et de l'architecture du modèle sont présentés dans le chapitre 2 consacré à la méthodologie et au pipeline IA.

1.7 MÉTHODOLOGIE ADOPTÉE

La démarche suivie comprend plusieurs étapes successives :

1. étude de l'existant et identification des indices de repeinture ;
2. comparaison qualitative des solutions d'acquisition ;
3. choix d'une configuration mobile macro ;
4. définition du protocole de capture ;
5. collecte et organisation des images ;
6. préparation du dataset ;
7. entraînement et évaluation du modèle ;
8. intégration expérimentale dans une interface web.

Cette méthodologie permet de relier l'étude théorique, l'acquisition de terrain, le développement du modèle et l'analyse des résultats.

La démarche a été conduite dans le cadre d'une expérimentation de durée limitée, avec une configuration d'acquisition unique basée sur un smartphone et un module Apexel. Les images ont été collectées dans différents environnements professionnels, puis organisées et utilisées pour entraîner un modèle EfficientNet-B0.

1.8 CONCLUSION

Dans ce chapitre, nous avons présenté le cadre général du projet, l'entreprise d'accueil et la plateforme MALLOULIAUTO. L'étude de l'existant et la comparaison des différentes solutions d'inspection nous ont permis de justifier le choix d'une approche mobile basée sur l'acquisition d'images macro. La solution retenue repose sur un smartphone associé à un module macro et sur un modèle EfficientNet-B0 pour la classification des surfaces d'origine et repeintes. Enfin, les objectifs, le périmètre et les contraintes du projet ont été définis. Le chapitre suivant sera consacré à la mise en œuvre de la solution retenue et à son intégration dans la plateforme.

Chapitre

2

MÉTHODOLOGIE ET PIPELINE IA

Sommaire

2.1 INTRODUCTION 11
2.2 PROTOCOLE D'ACQUISITION 11
2.2.1 ENVIRONNEMENTS DE COLLECTE 11
2.2.2 DISPOSITIF EXPÉRIMENTAL 12
2.2.3 PARAMÈTRES ET PROCÉDURE DE CAPTURE 14
2.3 CONSTITUTION DU DATASET 15
2.3.1 ORGANISATION DES DONNÉES 15
2.3.2 RÉPARTITION DES CLASSES ET DES SESSIONS 16
2.3.3 SÉPARATION TRAIN / VALIDATION / TEST 16
2.3.4 CONTRÔLE DES DOUBLONS ET DES FUITES 17
2.4 PRÉPARATION DES IMAGES 18
2.5 ARCHITECTURE ET STRATÉGIE D'ENTRAÎNEMENT . 20
2.5.1 VUE D'ENSEMBLE 20
2.5.2 PIPELINE DE TRAITEMENT D'IMAGE 21
2.5.3 ARCHITECTURE EFFICIENTNET-B0 22
2.5.4 ADAPTATION À LA CLASSIFICATION BINAIRE 24
2.5.5 GESTION DU DÉSÉQUILIBRE DES CLASSES 24
2.5.6 PHASE 1 : BACKBONE GELÉ 24
2.5.7 PHASE 2 : FINE-TUNING LIMITÉ 25
2.6 INTÉGRATION DANS LA PLATEFORME 25
2.6.1 COMMUNICATION ENTRE LE FRONTEND ET LE BACKEND 25
2.6.2 TRAITEMENT DE LA REQUÊTE ET RETOUR DU RÉSULTAT 26
2.7 CONCLUSION 27

2.1 INTRODUCTION

Ce chapitre décrit la démarche expérimentale mise en œuvre pour étudier la distinction entre une peinture automobile d'origine et une peinture repeinte.

La méthodologie adoptée comprend quatre étapes principales :

1. l'acquisition des images dans différents environnements professionnels ;
2. la constitution et l'organisation du dataset propriétaire ;
3. la préparation des images pour le modèle de Deep Learning ;
4. L'entraînement et l'intégration du modèle dans une interface de démonstration.

L'objectif n'est pas de proposer immédiatement une solution industrielle définitive, mais de mettre en place un pipeline expérimental permettant d'évaluer la faisabilité de l'approche dans les conditions disponibles.

2.2 PROTOCOLE D'ACQUISITION

2.2.1 ENVIRONNEMENTS DE COLLECTE

La collecte des images a été réalisée dans plusieurs environnements professionnels liés au secteur automobile.

Les images associées à la classe **repeint** ont été collectées dans des environnements comportant des zones de peinture et de séchage, notamment des ateliers spécialisés en tôlerie-carrosserie. Ces environnements ont permis d'observer des surfaces correspondant à des véhicules ayant subi des opérations de réparation ou de repeinture.

Les images associées à la classe **origine** ont été collectées auprès de sociétés automobiles disposant de véhicules neufs. Ces véhicules ont été retenus comme référence pour la classe correspondant aux surfaces de peinture d'origine.

Cette diversité des environnements permet d'introduire une variabilité entre les sessions de capture. Elle entraîne toutefois des différences possibles au niveau de l'éclairage, des véhicules, des couleurs et des surfaces observées.

Figure 2.1 présente les différents environnements professionnels dans lesquels les images ont été collectées.

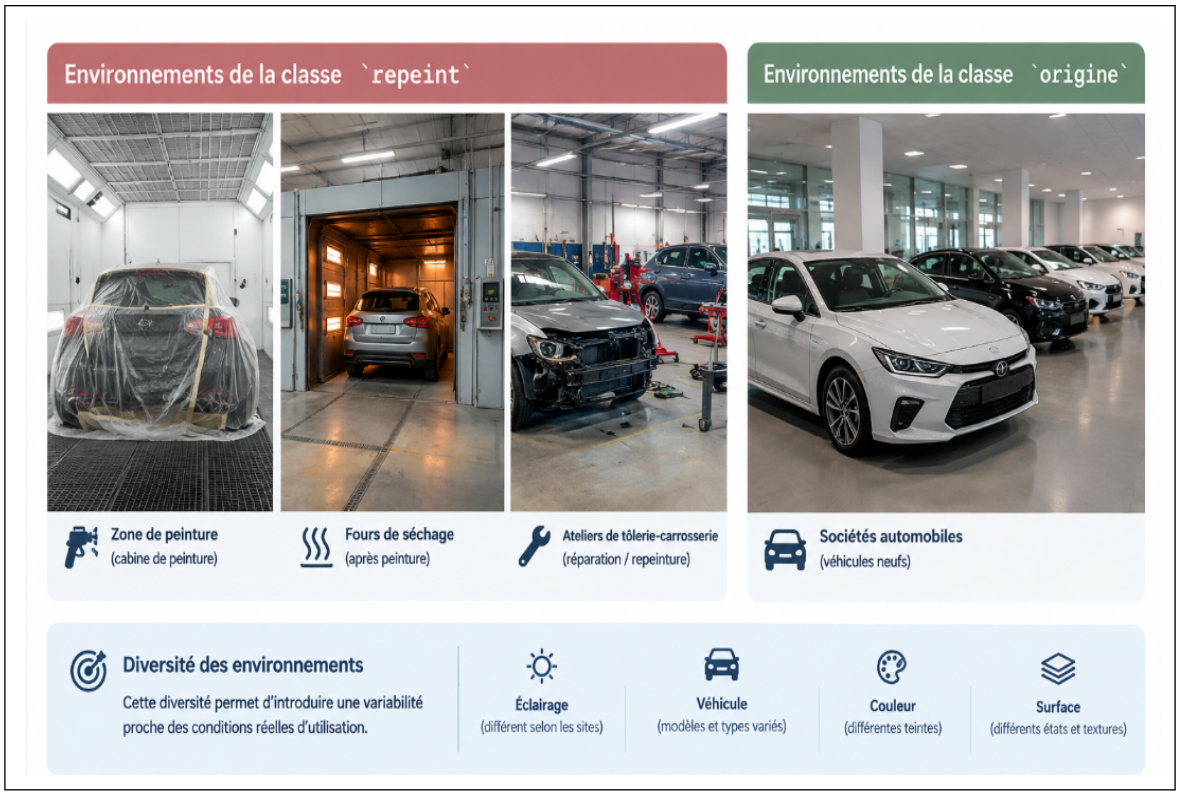


FIGURE 2.1 – Environnements professionnels de collecte

2.2.2 DISPOSITIF EXPÉRIMENTAL

Le dispositif expérimental retenu est composé d'un smartphone **Redmi Note 12** et d'un module optique macro **Apexel**.

Le smartphone assure l'acquisition des images, tandis que le module macro permet de réduire fortement la distance entre l'objectif et la surface observée afin de faire apparaître des détails de texture difficilement visibles sur une prise de vue classique.

Le module utilisé intègre également un éclairage LED et, selon la configuration, un filtre polarisant de type CPL. Ces éléments ont été utilisés afin de faciliter l'observation de la surface et de contrôler, dans certaines conditions, l'influence des reflets.

Le dispositif utilisé pour les acquisitions est présenté dans la figure 2.2.

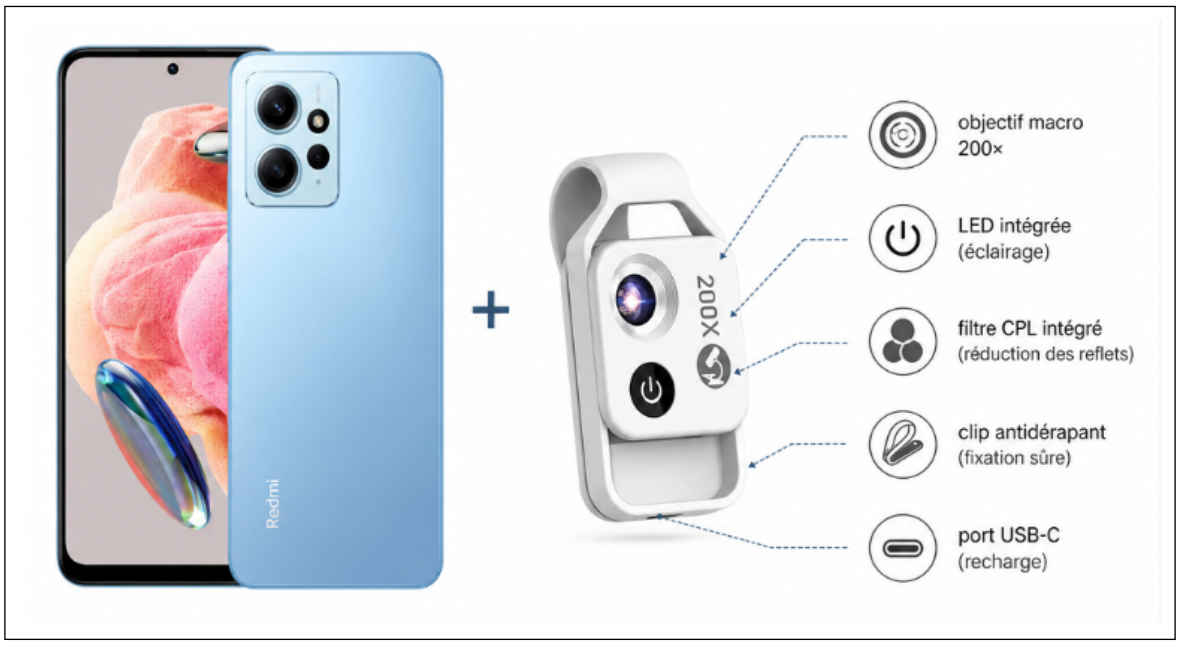


FIGURE 2.2 – Dispositif Redmi Note 12 équipé du module Apexel

OBSERVATION DE LA MACROTEXTURE DE LA PEINTURE

L'acquisition rapprochée permet d'observer des détails de texture présents à la surface de la peinture automobile. Ces variations de texture constituent une information visuelle complémentaire qui peut être exploitée dans le cadre de la classification des surfaces.

La figure 2.3 présente un exemple de texture observée lors des acquisitions rapprochées. Elle illustre le niveau de détail obtenu avec le dispositif macro utilisé dans cette étude. L'objectif n'est pas d'identifier visuellement une caractéristique particulière à partir de cette seule image, mais de fournir au modèle des informations locales sur l'aspect de la surface.

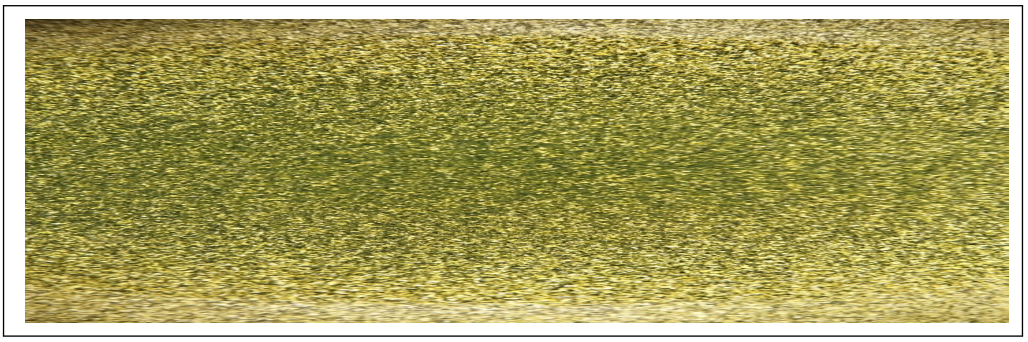


FIGURE 2.3 – Exemple de microtexture observée sur une surface automobile

2.2.3 PARAMÈTRES ET PROCÉDURE DE CAPTURE

Les paramètres de capture utilisés pendant la campagne sont présentés dans le tableau suivant.

TABLE 2.1 – Paramètres de capture utilisés

Paramètre	**Valeur**
Smartphone	Redmi Note 12
Module	Apexel
Mode caméra	Pro
Vitesse d'obturation	1/50 s
Balance des blancs	5600 K
Mise au point	Auto
Sensibilité ISO	Auto
Compensation d'exposition	0 EV
Objectif utilisé	W — Wide
Objectif UW	Non utilisé
Distance de travail	quasi nulle
Nombre de captures	2 à 3 par zone

Pour chaque zone étudiée, le module est positionné à une distance quasi nulle correspondant à la meilleure mise au point observée. La netteté de la zone centrale est ensuite vérifiée avant la capture.

Deux à trois images sont prises pour chaque zone afin de limiter le risque qu'une image isolée soit affectée par un flou, un reflet ou une variation momentanée de l'éclairage.

Le mode 50 MP a également été testé. Il a produit un vignettage circulaire et des bords assombris dans certaines conditions. Le mode standard est donc retenu comme configuration principale pour l'expérimentation.

2.3 CONSTITUTION DU DATASET

2.3.1 ORGANISATION DES DONNÉES

Les images sont organisées selon deux classes :

- origine ;
- repeint.

Après la préparation du dataset, les données sont réparties dans trois sous-ensembles :

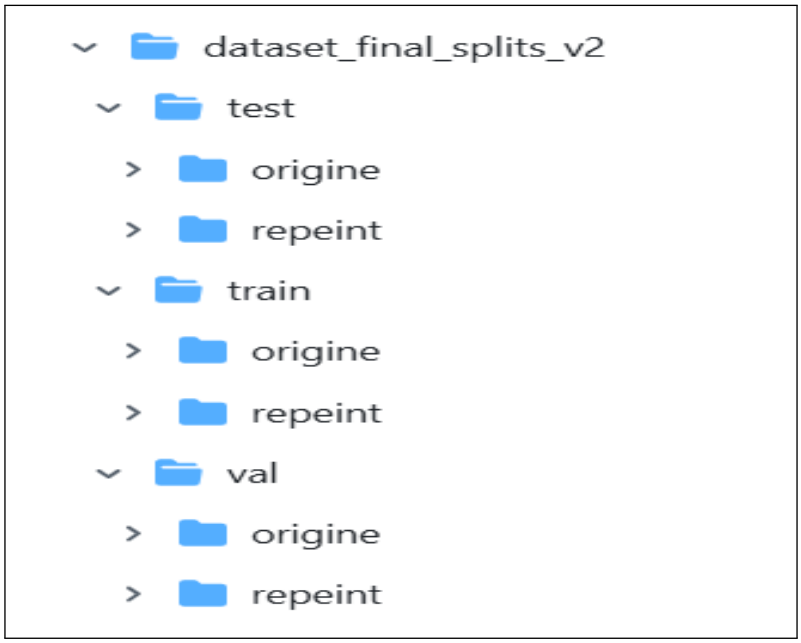


FIGURE 2.4 – Organisation du dataset en Train, Validation et Test

Le fichier de métadonnées permet d'associer chaque image à son nom, son chemin, son label, sa session de capture et son sous-ensemble.

Les informations principalement utilisées sont :

- `filename` ;

- `filepath`;
- `label`;
- `session_id`;
- `split`.

2.3.2 RÉPARTITION DES CLASSES ET DES SESSIONS

Le dataset propriétaire pilote contient environ 264 images réparties entre les deux classes.La répartition globale des images entre les deux classes est présentée dans le tableau 2.2.

TABLE 2.2 – Répartition globale du dataset

Classe	**Nombre d'images**
Origine	157
Repeint	107
Total	**264**

Les sessions de capture sont utilisées afin de conserver une traçabilité minimale et de limiter le mélange d'images issues de contextes différents.

Une session correspond à un groupe d'images capturées dans un même contexte de collecte. Lorsque cela est possible, les images d'une même session restent dans le même sous-ensemble.

2.3.3 SÉPARATION TRAIN / VALIDATION / TEST

La séparation retenue est présentée dans le tableau suivant.

TABLE 2.3 – Répartition des images par sous-ensemble

Sous-ensemble	**Origine**	**Repeint**	**Total**
Train	112	54	166
Validation	23	24	47
Test	22	29	51
Total	**157**	**107**	**264**

Le jeu **Train** est utilisé pour l'apprentissage du modèle. Le jeu **Validation** permet de suivre l'apprentissage et de sélectionner les meilleurs états du modèle. Le jeu **Test** est conservé pour l'évaluation finale.

La data augmentation est appliquée uniquement au jeu **Train**. Les images des jeux Validation et Test ne subissent pas ces transformations afin de conserver des données représentatives de l'évaluation.

2.3.4 CONTRÔLE DES DOUBLONS ET DES FUITES

Un contrôle des fichiers est effectué afin de vérifier :

- l'absence de noms de fichiers dupliqués ;
- l'absence d'un même fichier dans plusieurs sous-ensembles ;
- la cohérence des labels ;
- la présence des deux classes dans chaque sous-ensemble ;
- la séparation des sessions lorsque les identifiants sont disponibles.

Une attention particulière est accordée aux images prises dans une même zone. Deux images très similaires ne doivent pas être réparties entre Train et Test, car cette situation pourrait conduire à une estimation trop optimiste des performances.

2.4 PRÉPARATION DES IMAGES

REDIMENSIONNEMENT

Les images sont redimensionnées en 384×384 pixels afin de respecter le format d'entrée retenu pour EfficientNet-B0.

RECADRAGE CENTRAL

Le module Apexel peut produire un cercle lumineux ou un vignettage sur les bords de l'image. Un recadrage central fixe de **32 pixels par côté** est appliqué afin de limiter l'influence de ces zones périphériques.

La transformation est la suivante :

- Image initiale : **384** $\times$ **384**;
- Zone conservée : **320** $\times$ **320**;
- Redimensionnement : **384** $\times$ **384**.

Le recadrage est appliqué de manière identique aux jeux Train, Validation et Test.

NORMALISATION ET PRÉTRAITEMENT

Les images sont préparées afin d'être compatibles avec l'entrée du modèle EfficientNet-B0.

Dans l'implémentation Keras utilisée, le prétraitement propre à EfficientNet est intégré à l'architecture du modèle. La fonction preprocess_input d'EfficientNet est par conséquent une fonction pass-through dans les versions actuelles de Keras.

Ainsi, il convient de distinguer le **prétraitement géométrique**, réalisé par le pipeline de l'étude (recadrage et redimensionnement), du **prétraitement associé à EfficientNet**, intégré au modèle.

AUGMENTATION DES DONNÉES

Une augmentation modérée est appliquée uniquement pendant l'entraînement. Elle comprend :

- retournement horizontal ;
- rotation légère ;
- translation légère ;
- zoom limité ;
- variation modérée du contraste ;
- variation modérée de la luminosité.

Ces transformations sont volontairement limitées afin de ne pas altérer les détails fins de la texture de peinture. Les principales étapes de préparation d'une image sont illustrées dans la figure 2.5.

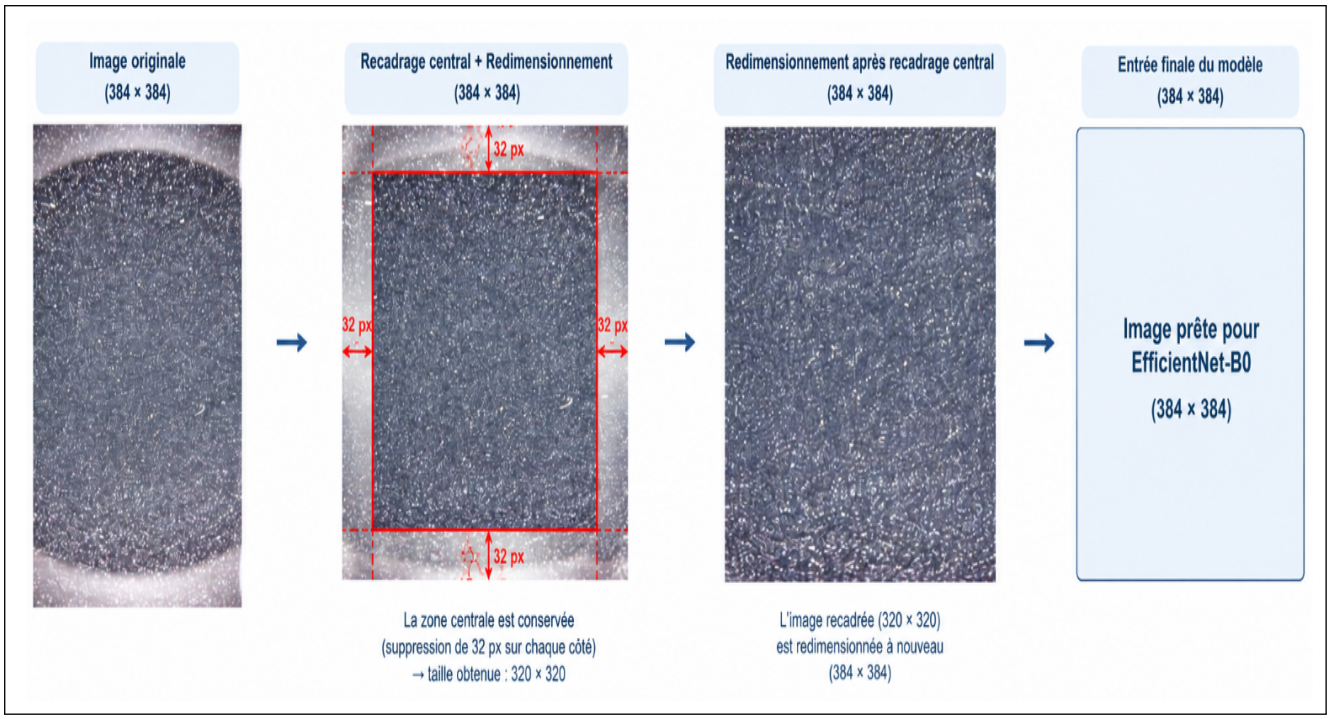


FIGURE 2.5 – Exemple de préparation d'une image avant l'inférence

2.5 ARCHITECTURE ET STRATÉGIE D'ENTRAÎNEMENT

2.5.1 VUE D'ENSEMBLE

La solution développée repose sur une architecture combinant un pipeline de traitement d'images, un modèle de Deep Learning et une interface web de démonstration. L'objectif est de permettre la classification d'une surface de peinture automobile selon deux classes : Origine et Repeint.

Le fonctionnement général peut être résumé par la chaîne suivante :

Image acquise → Préparation de l'image → EfficientNet-B0 → Probabilités → Règle de décision → Résultat

Le modèle de classification est exécuté côté serveur. L'interface web développée avec React permet à l'utilisateur de sélectionner une image et de demander son analyse. L'image est ensuite transmise au backend FastAPI, qui assure sa préparation et son traitement par le modèle. Les résultats sont finalement retournés à l'interface sous forme de données structurées.

Cette séparation permet de maintenir les poids du modèle côté serveur et de distinguer clairement les responsabilités du frontend et du backend.

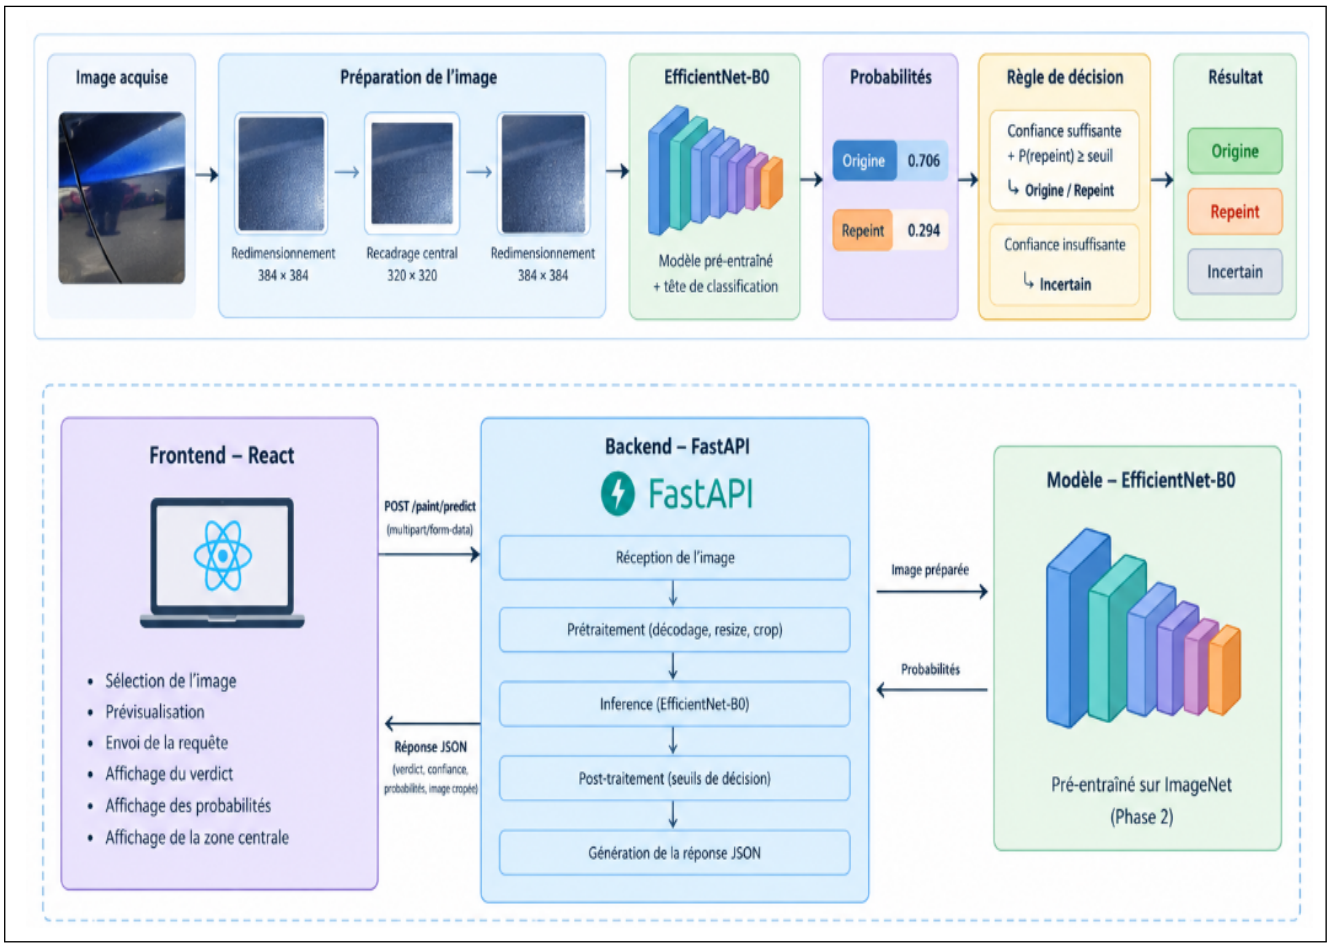


FIGURE 2.6 – Vue d'ensemble de l'architecture du système

2.5.2 PIPELINE DE TRAITEMENT D'IMAGE

Le pipeline de traitement constitue l'étape intermédiaire entre l'image acquise et son passage dans le modèle de classification. Les opérations appliquées doivent rester cohérentes avec celles utilisées lors de l'entraînement afin de limiter les différences entre les données d'apprentissage et les données utilisées lors de l'inférence.

L'image est tout d'abord représentée dans une résolution de 384 $\times$ 384 pixels. Un recadrage central de 32 pixels sur chacun des quatre côtés permet ensuite d'obtenir une zone de 320 $\times$ 320 pixels. Cette zone est redimensionnée à nouveau vers 384 $\times$ 384 pixels avant son entrée dans le réseau.

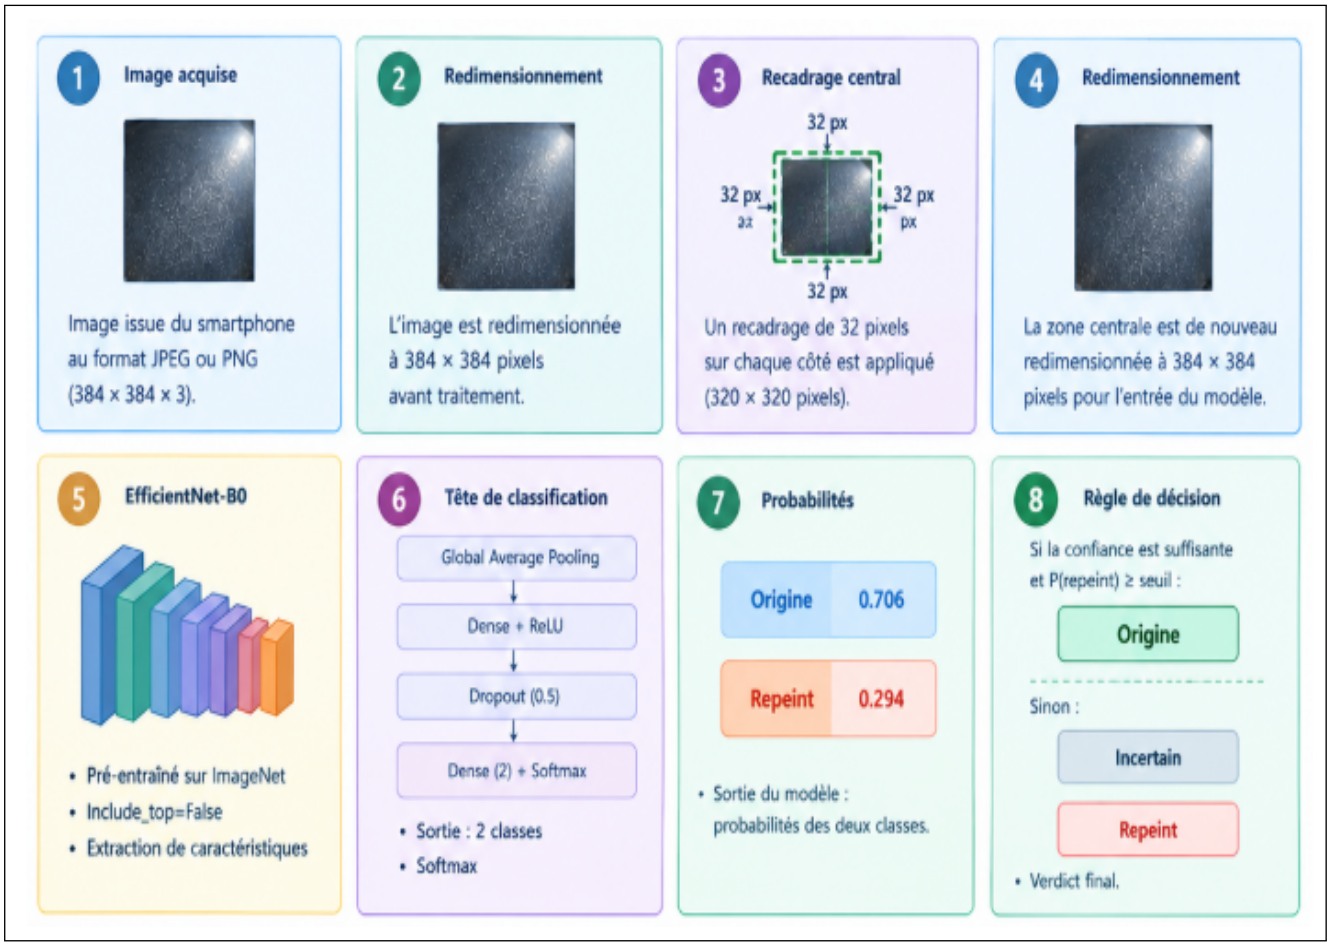


FIGURE 2.7 – pipeline général de traitement de l'image

Le recadrage central permet notamment de privilégier la partie centrale de l'image dans les conditions d'acquisition utilisées. Certaines images acquises avec le module macro peuvent présenter des variations périphériques, notamment un vignettage. Le choix de la zone centrale permet donc de limiter l'influence de ces zones lors de la classification.

Les mêmes opérations géométriques sont utilisées de manière cohérente entre la préparation des données d'entraînement et l'inférence.

2.5.3 ARCHITECTURE EFFICIENTNET-B0

Le modèle utilisé repose sur **EfficientNet-B0**, une architecture de réseau neuronal convolutif pré-entraînée sur la base de données **ImageNet**. Ce modèle est retenu dans le cadre de cette étude pour le compromis qu'il offre entre capacité de représentation et coût de calcul.

Dans une approche de **transfer learning**, le réseau pré-entraîné est utilisé comme base d'extraction de caractéristiques, tandis que sa tête de classification originale est adaptée à la nouvelle tâche. Cette stratégie permet de réutiliser des représentations visuelles apprises lors du pré-entraînement et de les adapter progressivement aux caractéristiques des surfaces de peinture automobile.

Dans le présent projet, EfficientNet-B0 est utilisé sans sa tête de classification originale afin de permettre l'adaptation du modèle à une tâche de classification binaire. Une nouvelle tête de classification est ensuite associée au backbone afin de produire une sortie correspondant aux deux classes étudiées : **Origine** et **Repeint**.

L'architecture générale du modèle et son adaptation à la tâche de classification sont présentées dans la figure 2.8.

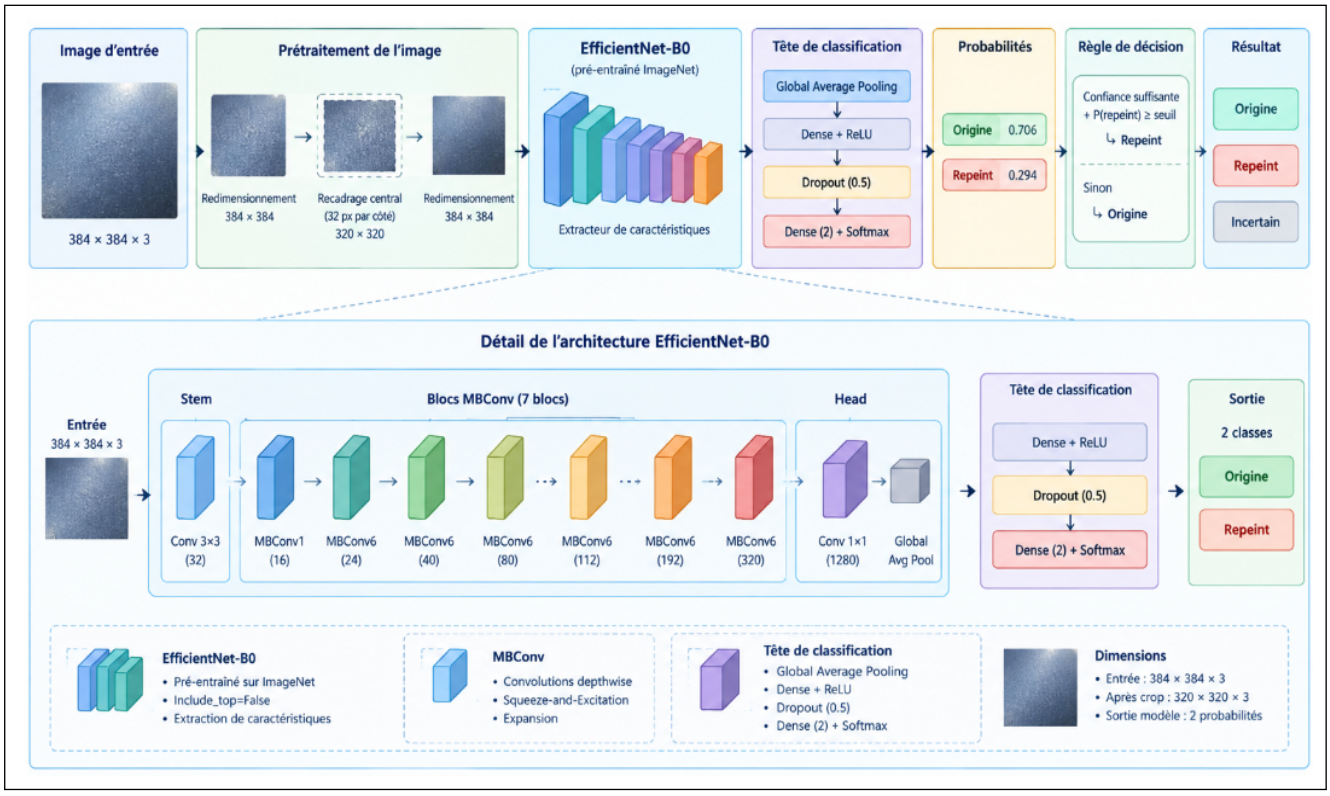


FIGURE 2.8 – ARCHITECTURE DU MODÈLE DE CLASSIFICATION

2.5.4 ADAPTATION À LA CLASSIFICATION BINAIRE

Le modèle initialement pré-entraîné sur ImageNet est utilisé comme extracteur de caractéristiques. Sa tête de classification originale est remplacée par une nouvelle tête comprenant une sortie Softmax à deux classes.

L'ordre des sorties est fixé comme suit :

- **Indice 0** : origine ;
- **Indice 1** : repeint.

Cette convention est conservée dans le notebook, dans le backend et dans l'interface web afin d'éviter toute inversion des verdicts.

2.5.5 GESTION DU DÉSÉQUILIBRE DES CLASSES

Le dataset contient davantage d'images originales que d'images repeintes. Sans correction, le modèle pourrait favoriser la classe majoritaire.

Des **poids de classes** sont donc utilisés pendant l'entraînement. Le poids associé à une classe est calculé en fonction de sa représentation dans le jeu Train.

Cette méthode ne crée pas de nouvelles images, mais augmente l'importance des erreurs commises sur la classe minoritaire pendant l'optimisation.

2.5.6 PHASE 1 : BACKBONE GELÉ

Dans la première phase, le backbone EfficientNet-B0 reste gelé. Seule la tête de classification est entraînée.

Cette phase permet :

- d'adapter rapidement le modèle aux deux classes ;
- de conserver les caractéristiques générales apprises sur ImageNet ;
- de limiter le risque de surapprentissage ;

- d'obtenir une première baseline.

Le learning rate utilisé pour cette phase est :

- `1e-3`.

Un mécanisme d' **Early Stopping** est utilisé afin d'arrêter l'apprentissage lorsque la validation ne s'améliore plus.

2.5.7 PHASE 2 : FINE-TUNING LIMITÉ

Dans la deuxième phase, un nombre limité de couches finales du backbone est dégelé. Le learning rate est réduit afin d'éviter une modification trop importante des poids pré-entraînés.

La configuration utilisée comprend :

- **Learning rate :** `1e-5`**;**
- **Dernières couches dégelées : 5 ;**
- **Batch Normalization : gelées.**

Cette phase vise à adapter plus finement les caractéristiques du réseau aux textures spécifiques des surfaces automobiles.

Le fine-tuning peut améliorer l'adaptation du modèle aux nouvelles données, mais augmente également le risque de surapprentissage lorsque le dataset reste limité. Keras recommande justement un faible taux d'apprentissage lors du fine-tuning et le maintien des couches Batch Normalization dans un état gelé dans ce type de procédure.

2.6 INTÉGRATION DANS LA PLATEFORME

2.6.1 COMMUNICATION ENTRE LE FRONTEND ET LE BACKEND

Afin de démontrer l'intégration du modèle dans la plateforme, une interface web React a été développée en complément du backend FastAPI. Le modèle de classification et ses poids restent exécutés côté serveur ; le frontend ne charge donc pas directement le fichier du modèle.

Lorsqu'une image est sélectionnée par l'utilisateur, le frontend prépare une requête contenant le fichier et l'envoie au backend à travers l'endpoint dédié :

`POST /paint/predict`

L'image est transmise sous la forme d'un fichier multipart. Le champ utilisé pour l'envoi est `file` et les formats JPEG et PNG sont acceptés. FastAPI fournit nativement la gestion des fichiers reçus sous forme de données `multipart/form-data`.

Le flux de communication est donc le suivant :

Sélection de l'image → React → `POST /paint/predict` → FastAPI → Modèle de classification

Cette organisation permet de séparer clairement l'interface utilisateur de la logique d'inférence et de conserver les poids du modèle uniquement côté backend.

2.6.2 TRAITEMENT DE LA REQUÊTE ET RETOUR DU RÉSULTAT

À la réception de la requête, le backend vérifie le fichier transmis puis effectue les opérations nécessaires à son traitement avant l'exécution de l'inférence. Le modèle EfficientNet-B0 utilisé pour la Phase 2 applique ensuite le pipeline de préparation défini précédemment et produit les probabilités associées aux deux classes.

La décision finale est obtenue à partir de ces probabilités selon les seuils définis dans le système. Le backend retourne ensuite une réponse structurée au frontend contenant notamment :

- le verdict ;
- la confiance associée ;
- les probabilités des classes Origine et Repeint ;
- la version du modèle ;
- le statut expérimental.

Une représentation de la zone centrale peut également être générée séparément afin d'être affichée dans l'interface de démonstration.

Le fonctionnement global peut être résumé ainsi :

Image reçue → Vérification → Préparation → EfficientNet-B0 → Probabilités → Règle de décision → Réponse JSON

Le traitement du modèle reste ainsi centralisé côté serveur, tandis que le frontend se limite à la sélection de l'image, à l'envoi de la requête et à la présentation du résultat.

2.7 CONCLUSION

Ce chapitre a présenté la méthodologie expérimentale adoptée pour l'acquisition et la constitution des données, la préparation des images, l'entraînement du modèle ainsi que son intégration technique dans la plateforme.

Le protocole d'acquisition repose sur un smartphone Redmi Note 12 associé à un module macro Apexel. Les images collectées ont ensuite été organisées dans un jeu de données pilote propriétaire comprenant deux classes : **origine** et **Repeint**.

Après préparation, les images ont été utilisées pour entraîner un modèle **EfficientNet-B0** pré-entraîné selon une stratégie en deux phases : une première phase avec le backbone gelé, suivie d'un fine-tuning limité.

Enfin, l'intégration technique du modèle dans le backend **FastAPI**, ainsi que la communication avec le frontend, a été présentée, notamment via l'endpoint dédié à la classification.

Le chapitre suivant présente les résultats obtenus, l'évaluation des performances du modèle, ainsi que la démonstration de l'interface web et l'analyse de ses erreurs et de ses limites expérimentales.

Chapitre

3

RÉSULTATS ET ANALYSE

Sommaire

3.1 INTRODUCTION 29
3.2 RÉSULTATS DE L'ENTRAÎNEMENT 29
3.2.1 PERFORMANCE DU MODÈLE 29
3.2.2 COMPARAISON DES DEUX PHASES D'ENTRAÎNEMENT 31
3.3 ÉVALUATION DU MODÈLE 32
3.3.1 MATRICE DE CONFUSION 32
3.3.2 INDICATEURS DE PERFORMANCE 33
3.3.3 COURBE ROC ET AUC 34
3.4 ANALYSE DES ERREURS 35
3.4.1 FAUX POSITIFS ET FAUX NÉGATIFS 35
3.4.2 INFLUENCE DES CONDITIONS DE CAPTURE 36
3.4.3 ARTEFACTS OPTIQUES OBSERVÉS 36
3.4.4 LIMITES LIÉES AU DATASET 37
3.5 GESTION DES PRÉDICTIONS INCERTAINES 37
3.5.1 NÉCESSITÉ D'UNE ZONE D'INCERTITUDE 37
3.5.2 PRINCIPE DE DÉCISION 38
3.5.3 INTÉRÊT POUR UNE UTILISATION EN INSPECTION . . 39
3.6 INTERFACE WEB DE DÉMONSTRATION 40
3.6.1 PRÉSENTATION DE L'INTERFACE 40
3.6.2 SÉLECTION ET PRÉVISUALISATION DE L'IMAGE 40
3.6.3 LANCEMENT DE L'ANALYSE 41
3.6.4 AFFICHAGE DU RÉSULTAT ET DE LA ZONE CENTRALE 42
3.7 DISCUSSION DES RÉSULTATS ET RECOMMANDATIONS 43
3.7.1 INTERPRÉTATION DES RÉSULTATS 43
3.7.2 APPORTS ET LIMITES DE L'APPROCHE 44
3.8 CONCLUSION 45

3.1 INTRODUCTION

Ce chapitre présente les résultats obtenus après l'entraînement et l'évaluation du modèle de classification de peinture automobile. L'analyse porte successivement sur les résultats de l'entraînement, la comparaison des deux phases d'apprentissage, les performances obtenues sur le jeu de test, la matrice de confusion, la courbe ROC ainsi que les principales erreurs de classification. Une attention particulière est également accordée aux conditions d'acquisition, aux artefacts optiques observés et aux limites liées au dataset. Enfin, une stratégie de gestion des prédictions incertaines ainsi que l'interface web développée pour la démonstration du modèle sont présentées. Les résultats doivent être interprétés dans le contexte d'une étude de faisabilité réalisée sur un dataset propriétaire pilote. Ils ne constituent pas une validation industrielle définitive du système.

3.2 RÉSULTATS DE L'ENTRAÎNEMENT

3.2.1 PERFORMANCE DU MODÈLE

L'entraînement du modèle est réalisé en deux phases. La première phase consiste à entraîner la tête de classification tout en conservant le backbone EfficientNet-B0 pré-entraîné gelé. La seconde phase correspond à un fine-tuning limité des dernières couches du backbone afin d'adapter progressivement les représentations apprises au domaine étudié.

La fonction de perte permet de mesurer l'écart entre les prédictions du modèle et les labels réels. L'accuracy représente la proportion d'images correctement classées.

La comparaison des courbes d'apprentissage et de validation permet d'évaluer la capacité de généralisation du modèle et d'identifier d'éventuels phénomènes de surapprentissage. Une augmentation continue de l'accuracy d'entraînement accompagnée d'une stagnation ou d'une diminution de l'accuracy de validation peut notamment indiquer que le modèle apprend des caractéristiques trop spécifiques aux données d'entraînement.

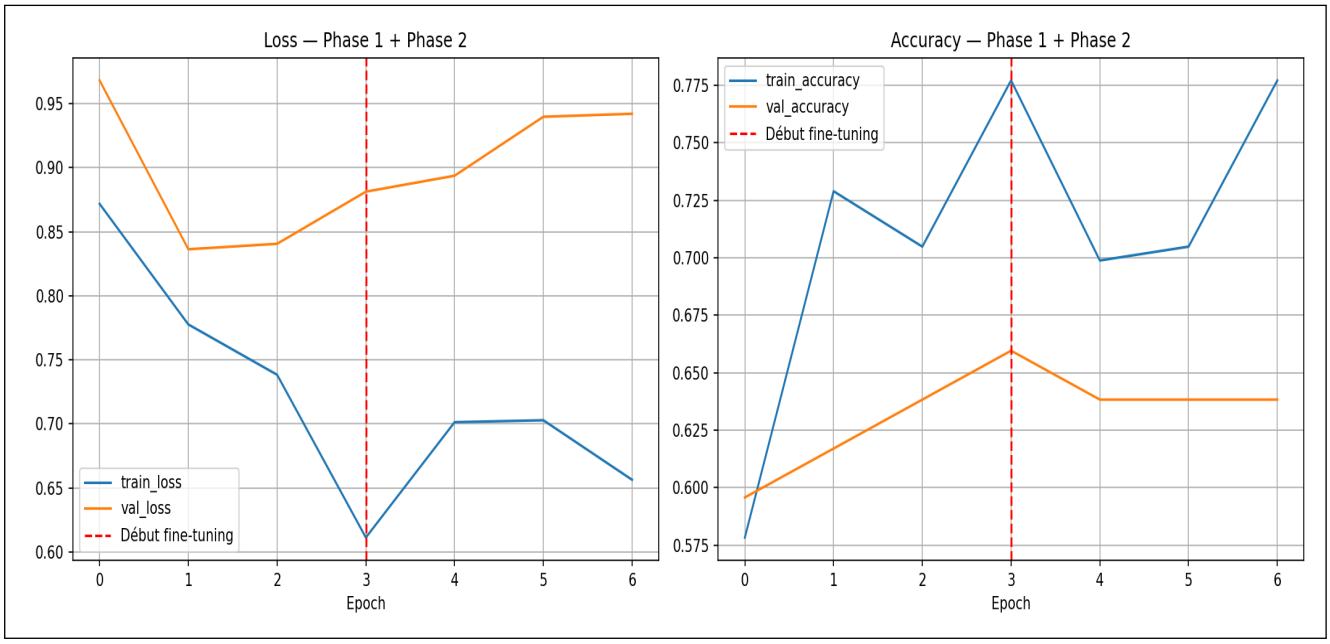


FIGURE 3.1 – Évolution de la fonction de perte et de l'accuracy pendant les deux phases d'entraînement

Les courbes obtenues montrent que l'accuracy d'entraînement progresse davantage que l'accuracy de validation. La validation présente également une plus grande variabilité et la fonction de perte de validation ne diminue pas de manière parfaitement régulière.

Ces observations montrent que le modèle possède une capacité réelle d'apprentissage, mais que sa généralisation reste limitée dans les conditions expérimentales considérées.

Plusieurs facteurs peuvent contribuer à cette situation :

- la taille réduite du dataset ;
- le déséquilibre entre les deux classes ;
- la variabilité des véhicules et des surfaces étudiées ;
- les différences entre les sessions de capture ;
- les variations d'éclairage et de mise au point ;
- les différences de texture et de couleur des surfaces.

Ces résultats justifient donc l'utilisation d'une stratégie de transfert d'apprentissage et d'un fine-tuning limité, plutôt qu'un entraînement complet du réseau à partir de zéro.

3.2.2 COMPARAISON DES DEUX PHASES D'ENTRAÎNEMENT

La Phase 1 permet d'adapter rapidement la tête de classification aux deux classes du projet :

- origine ;
- repeint.

Le backbone EfficientNet-B0 reste gelé afin de limiter le nombre de paramètres entraînables et de réduire le risque de surapprentissage sur un dataset de taille limitée.

La Phase 2 consiste ensuite à déverrouiller un nombre limité de couches finales du backbone. Le learning rate est réduit afin de permettre une adaptation progressive des représentations du réseau aux images acquises dans le contexte de l'étude.

Cette stratégie est cohérente avec le principe du transfer learning : le modèle pré-entraîné est d'abord utilisé comme extracteur de caractéristiques, puis une partie limitée du réseau est ajustée à l'aide d'un learning rate plus faible.

Dans le dernier entraînement retenu, la Phase 2 a fourni les meilleurs résultats parmi les configurations évaluées. La sélection du modèle doit toutefois être fondée prioritairement sur les performances obtenues sur le jeu de validation, tandis que le jeu de test est conservé pour l'évaluation finale.

TABLE 3.1 – Comparaison qualitative des deux phases

Élément	**Phase 1**	**Phase 2**
Backbone	Gelé	Partiellement dégelé
Objectif	Adapter la tête de classification	Adapter les dernières représentations
Learning rate	1e-3	1e-5
Risque principal	Sous-adaptation au domaine	Surapprentissage
Utilité	Baseline stable	Affinement du modèle

Les résultats de cette comparaison doivent être interprétés en tenant compte de la taille réduite du dataset. Une différence de performance entre les deux phases peut varier selon la séparation des données et les caractéristiques des sessions de capture.

3.3 ÉVALUATION DU MODÈLE

3.3.1 MATRICE DE CONFUSION

La matrice de confusion permet d'observer les décisions du modèle pour chacune des deux classes sur le jeu de test.

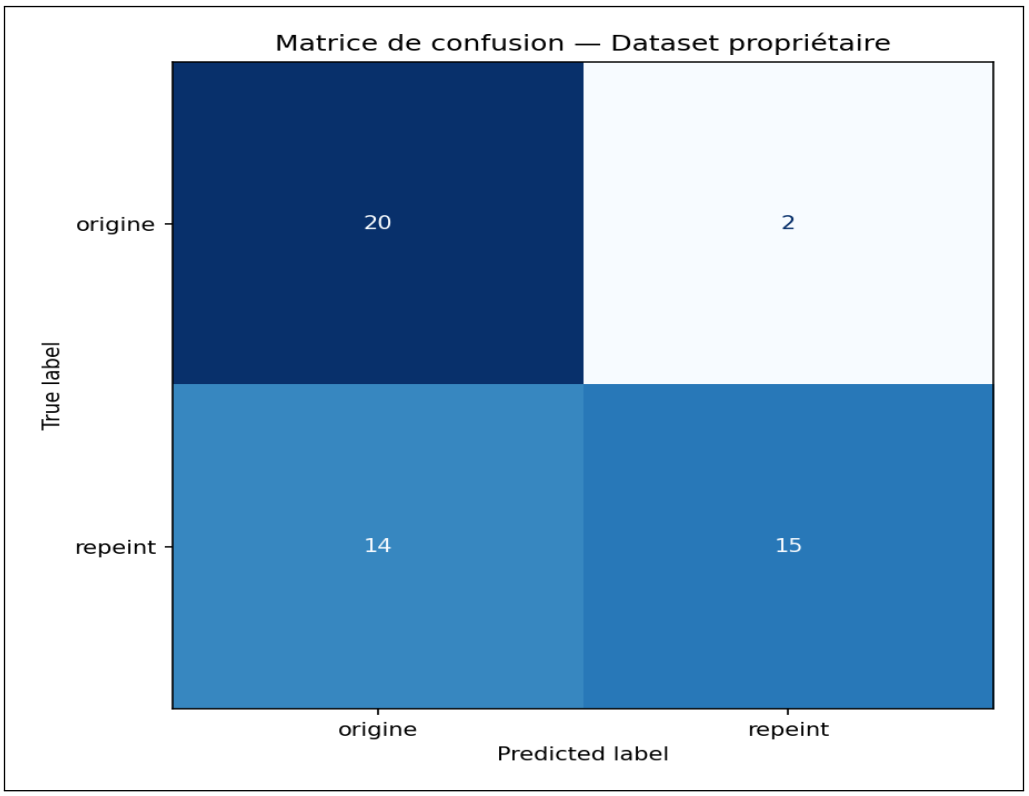


FIGURE 3.2 – Matrice de confusion sur le jeu de test

Sur les 51 images du jeu de test, le modèle a correctement classé :

- 20 images d'origine sur 22 ;
- 15 images repeintes sur 29.

Les erreurs sont réparties comme suit :

- 2 images d'origine classées comme repeintes ;
- 14 images repeintes classées comme originaires.

Le modèle présente ainsi une tendance à reconnaître plus facilement les surfaces d'origine que les surfaces repeintes.

Cette tendance est particulièrement visible pour la classe Repeint, dont 14 images sur 29 ne sont pas détectées correctement.

3.3.2 INDICATEURS DE PERFORMANCE

Les performances obtenues sur le jeu de test sont présentées dans le tableau suivant.

TABLE 3.2 – Indicateurs de performance du modèle sur le jeu de test

Métrique	**Résultat**
Test loss	0,8098
Accuracy	68,63 %
Balanced Accuracy	71,32 %
F1-score macro	68,32 %
Precision Origine	58,82 %
Recall Origine	90,91 %
F1 Origine	71,43 %
Precision Repeint	88,24 %
Recall Repeint	51,72 %
F1 Repeint	65,22 %
Nombre d'erreurs	16 / 51

L'accuracy obtenue est de 68,63 %. La balanced accuracy, égale à 71,32 %, est présentée en complément afin de tenir compte du déséquilibre entre les deux classes.

La différence entre les performances des deux classes est particulièrement importante. Le rappel de la classe Origine atteint 90,91 %, tandis que celui de la classe Repeint est limité à 51,72

Le rappel de la classe Repeint constitue un indicateur important dans le contexte du projet, puisqu'il représente la proportion de surfaces effectivement repeintes que le modèle parvient à identifier.

Le résultat obtenu signifie que plusieurs surfaces repeintes sont encore classées comme originaires. À l'inverse, la précision de la classe Repeint atteint 88,24 %, ce qui indique que lorsqu'une image est classée comme repeinte, cette prédiction est généralement correcte dans le jeu de test.

Ces résultats montrent donc que le modèle possède une capacité de discrimination entre les deux classes, mais que la détection des surfaces repeintes reste insuffisante pour une utilisation industrielle autonome.

3.3.3 COURBE ROC ET AUC

La courbe ROC permet d'étudier le comportement du modèle pour différents seuils de décision. L'AUC représente la capacité du modèle à distinguer les deux classes lorsqu'un ensemble de seuils est considéré.

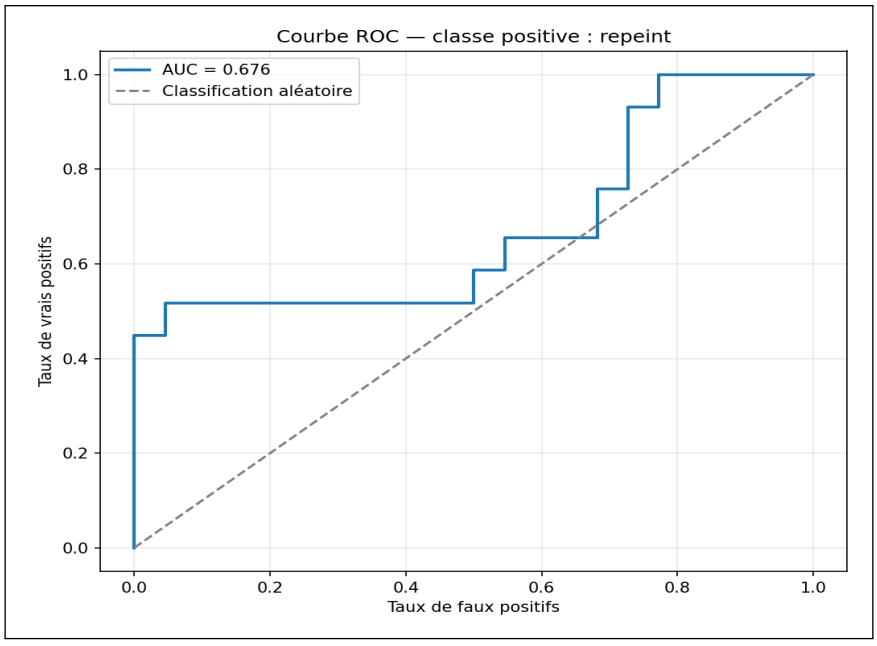


FIGURE 3.3 – Courbe ROC pour la classe positive Repeint

Lors du dernier entraînement, l'AUC obtenue pour la classe Repeint est :

$$\texttt{AUC = 0,6755}$$

Cette valeur indique qu'un signal discriminant existe dans les images, mais que la séparation reste modérée. Elle est inférieure à l'objectif expérimental initial de 0,85.

L'AUC doit être interprétée avec prudence, car le jeu de test contient un nombre limité d'images et plusieurs sessions de capture peuvent présenter des caractéristiques différentes.

3.4 ANALYSE DES ERREURS

3.4.1 FAUX POSITIFS ET FAUX NÉGATIFS

Un faux positif correspond à une image d'origine classée comme repeinte. Un faux négatif correspond à une image repeinte classée comme origine.

Dans le dernier résultat :

- Faux positifs Origine $\rightarrow$ Repeint : 2 ;
- Faux négatifs Repeint $\rightarrow$ Origine : 14.

TABLE 3.3 – Répartition des erreurs

Type d'erreur	**Nombre**	**Interprétation**
Origine classée Repeint	2	Faux positifs
Repeint classée Origine	14	Faux négatifs
Total	**16**	Erreurs sur le test

Les faux négatifs sont nettement plus nombreux que les faux positifs. Cette répartition montre une tendance du modèle à classer certaines surfaces comme étant d'origine alors qu'elles sont effectivement repeintes.

Cette situation est particulièrement importante dans le contexte de l'inspection automobile, car une surface repeinte peut ne pas être signalée par le système.

La réduction des faux négatifs constitue donc un axe d'amélioration prioritaire pour les futures versions du modèle.

3.4.2 INFLUENCE DES CONDITIONS DE CAPTURE

Les résultats peuvent être influencés par :

- l'intensité de l'éclairage ;
- l'orientation du module ;
- la distance entre l'objectif et la surface ;
- la mise au point automatique ;
- la couleur de la peinture ;
- la brillance du vernis ;
- la zone de la pièce capturée.

Les nouvelles images repeintes peuvent présenter une distribution différente de celle des images utilisées pendant l'entraînement. Cette différence peut expliquer la baisse des performances sur certaines sessions. La généralisation du modèle dépend donc non seulement de l'architecture utilisée, mais également de la diversité et de la représentativité des données d'apprentissage.

3.4.3 ARTEFACTS OPTIQUES OBSERVÉS

Le module Apexel peut produire un cercle lumineux ou un vignettage sur les bords de l'image, notamment dans certains modes de capture.

Ces artefacts peuvent être appris par le modèle à la place des caractéristiques réelles de la peinture. Pour limiter leur influence, un recadrage central de 32 pixels par côté est appliqué.

Le recadrage permet également de montrer à l'utilisateur, dans l'interface web, la zone centrale réellement exploitée pour l'analyse.

Cependant, le recadrage ne supprime pas totalement l'influence des conditions d'acquisition. Il doit être associé à un protocole stable concernant la distance, l'exposition, la balance des blancs et l'éclairage.

3.4.4 LIMITES LIÉES AU DATASET

Les principales limites du dataset sont :

- nombre encore limité d'images ;
- déséquilibre entre les classes ;
- nombre limité de véhicules ;
- diversité partielle des pièces automobiles ;
- diversité limitée des couleurs ;
- variabilité entre les sessions ;
- absence d'une validation sur un grand nombre de véhicules indépendants ;
- La vérité est dépendante des informations disponibles auprès des professionnels.

Le dataset comprend plusieurs captures réalisées dans une même zone. Les deux à trois captures effectuées par zone permettent d'observer la répétabilité immédiate de l'acquisition, mais elles ne constituent pas nécessairement des observations indépendantes.

Pour une évaluation future, une séparation stricte par véhicule, pièce ou session devra être privilégiée afin de réduire le risque qu'un même contexte visuel soit représenté simultanément dans les différents sous-ensembles.

3.5 GESTION DES PRÉDICTIONS INCERTAINES

3.5.1 NÉCESSITÉ D'UNE ZONE D'INCERTITUDE

Dans une application d'inspection automobile, une décision automatique ne doit pas toujours être imposée. Certaines images peuvent être ambiguës ou éloignées des conditions rencontrées pendant l'entraînement.

Pour cette raison, un état supplémentaire appelé Incertain est généré en post-traitement. Il ne constitue pas une troisième classe entraînée par le réseau.

Cet état permet d'éviter de fournir un verdict trop affirmatif lorsque la confiance du modèle est faible.

3.5.2 PRINCIPE DE DÉCISION

Le modèle produit deux probabilités correspondant aux deux classes étudiées :

- $P(\text{origine})$;
- $P(\text{repeint})$.

Ces probabilités vérifient :

$$P(\text{origine}) + P(\text{repeint}) = 1$$

SÉLECTION DU SEUIL DE CLASSIFICATION

Le seuil de classification de la classe Repeint a été recherché sur le jeu de validation. Plusieurs valeurs comprises entre 0,20 et 0,60, avec un pas de 0,01, ont été testées. Pour chaque valeur, les performances de classification ont été comparées à l'aide de la précision, du rappel, du F1-score de la classe Repeint, du F1-score macro et de la balanced accuracy.

Le seuil offrant le meilleur compromis sur le jeu de validation a été fixé à :

$$T_{\text{Repeint}} = 0,52$$

La règle de classification est donc :

```
si P(repeint) >= 0.52 -> Repeint ;
sinon -> Origine.
```

SÉLECTION DU SEUIL DE REJET INCERTAIN

Un second seuil est utilisé afin d'éviter de produire un verdict lorsque la confiance du modèle est insuffisante. La confiance maximale est définie par :

$$C = \max(P(\text{origine}), P(\text{repeint}))$$

Dans l'expérimentation réalisée, un seuil de confiance de 0,65 a été retenu. Il permet de rejeter les prédictions pour lesquelles les probabilités restent trop proches.

Ainsi :

$$C < 0,65 \rightarrow \text{Incertain}$$

RÈGLE FINALE DE DÉCISION

La décision finale s'effectue en deux étapes :

```
si confiance maximale < 0.65 -> Incertain ;
si confiance maximale >= 0.65 et P(repeint) >= 0.52 -> Repeint ;
si confiance maximale >= 0.65 et P(repeint) < 0.52 -> Origine.
```

Les seuils sont déterminés à partir du jeu de validation. Le jeu de test est conservé pour l'évaluation finale et n'est pas utilisé pour leur sélection.

3.5.3 INTÉRÊT POUR UNE UTILISATION EN INSPECTION

L'état Incertain permet de transmettre le cas à un expert humain au lieu de produire automatiquement un verdict potentiellement incorrect.

Cette stratégie est intéressante dans un contexte d'inspection, car elle permet de privilégier la prudence. Elle peut cependant réduire la couverture du système si le seuil est trop élevé.

Il faut donc rechercher un compromis entre :

- taux de bonnes prédictions ;
- rappel de la classe Repeint ;
- nombre de cas rejetés ;
- taux de couverture.

3.6 INTERFACE WEB DE DÉMONSTRATION

3.6.1 PRÉSENTATION DE L'INTERFACE

Une interface React a été développée afin de présenter les résultats du modèle de classification de peinture.

La page est accessible par la route :

- `/paint-inspection`.

Dans l'environnement local, elle est disponible à l'adresse :

- `http://localhost:3000/paint-inspection`.

L'interface est séparée de la page principale d'analyse automobile et communique avec le backend via l'endpoint :

- `POST /paint/predict`.

Le modèle n'est pas chargé dans le frontend. L'inférence est réalisée côté serveur afin de conserver la logique de traitement et les fichiers du modèle au niveau du backend.

3.6.2 SÉLECTION ET PRÉVISUALISATION DE L'IMAGE

L'utilisateur peut sélectionner une seule image au format JPEG ou PNG. L'image est affichée dans l'interface avant le lancement de l'analyse.

Cette étape permet de vérifier que :

- l'image est correctement chargée ;
- la zone automobile est visible ;
- le format est accepté ;
- L'utilisateur a sélectionné la bonne image.

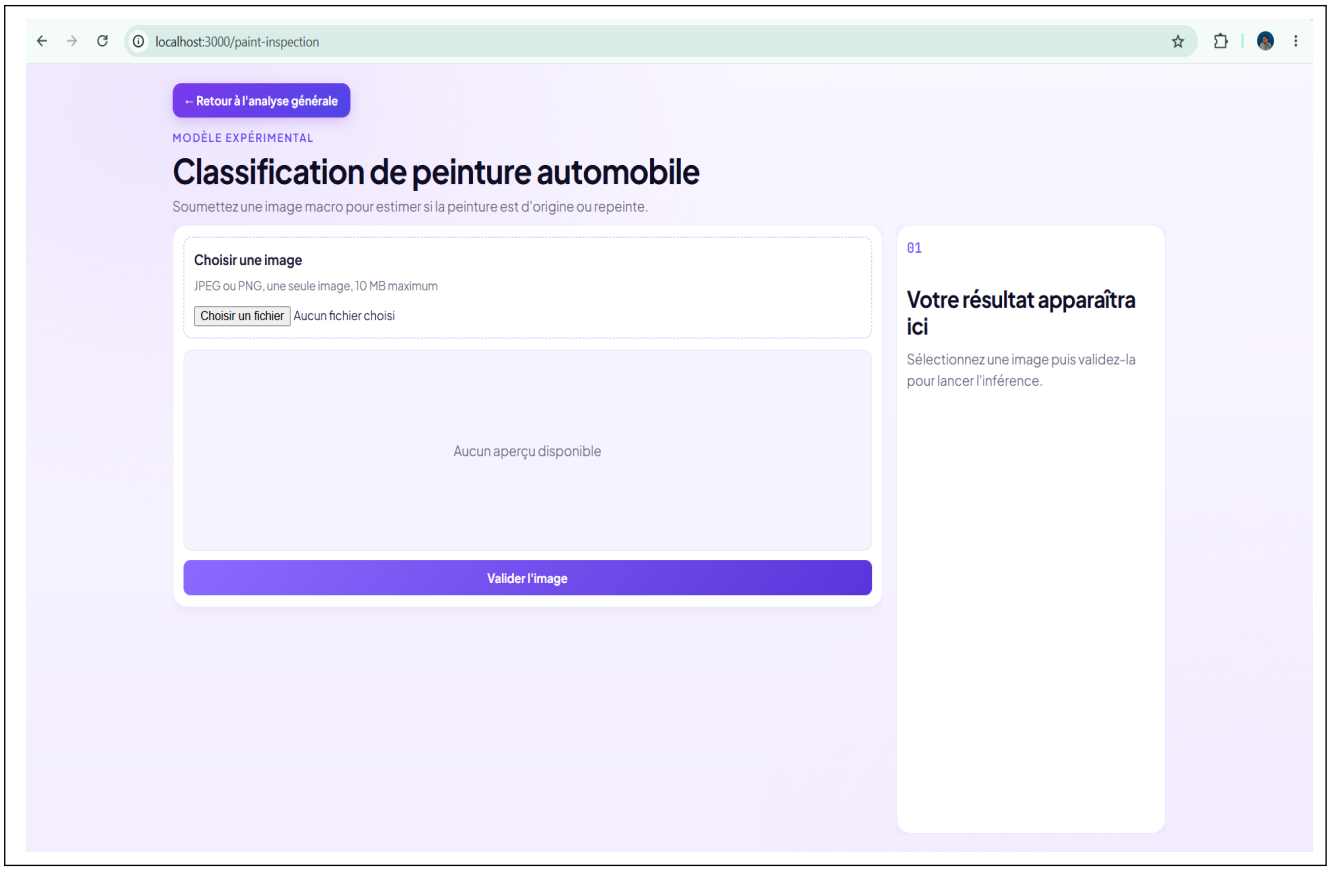


FIGURE 3.4 – Interface web avant le lancement de l'analyse

3.6.3 LANCEMENT DE L'ANALYSE

L'analyse est lancée lorsque l'utilisateur clique sur le bouton de validation.

Le frontend envoie l'image au backend sous la forme d'une requête multipart. Le backend réalise ensuite :

1. la lecture de l'image ;
2. son décodage ;
3. son prétraitement ;
4. son passage dans EfficientNet-B0 ;

5. le calcul des probabilités ;
6. l'application des seuils de décision ;
7. la génération de la réponse.

Le résultat est ensuite transmis à l'interface afin d'être présenté à l'utilisateur.

3.6.4 AFFICHAGE DU RÉSULTAT ET DE LA ZONE CENTRALE

Après l'inférence, l'interface affiche le verdict produit par le modèle, le niveau de confiance ainsi que les probabilités associées aux classes « Origine » et « Repeint ».

Lorsque la confiance maximale est inférieure au seuil défini, le système affiche l'état « Incertain ».

L'interface présente également la zone centrale utilisée dans le processus de préparation de l'image. Cette visualisation permet de rendre le prétraitement plus transparent pour l'utilisateur et de montrer la partie de l'image considérée lors de l'analyse.

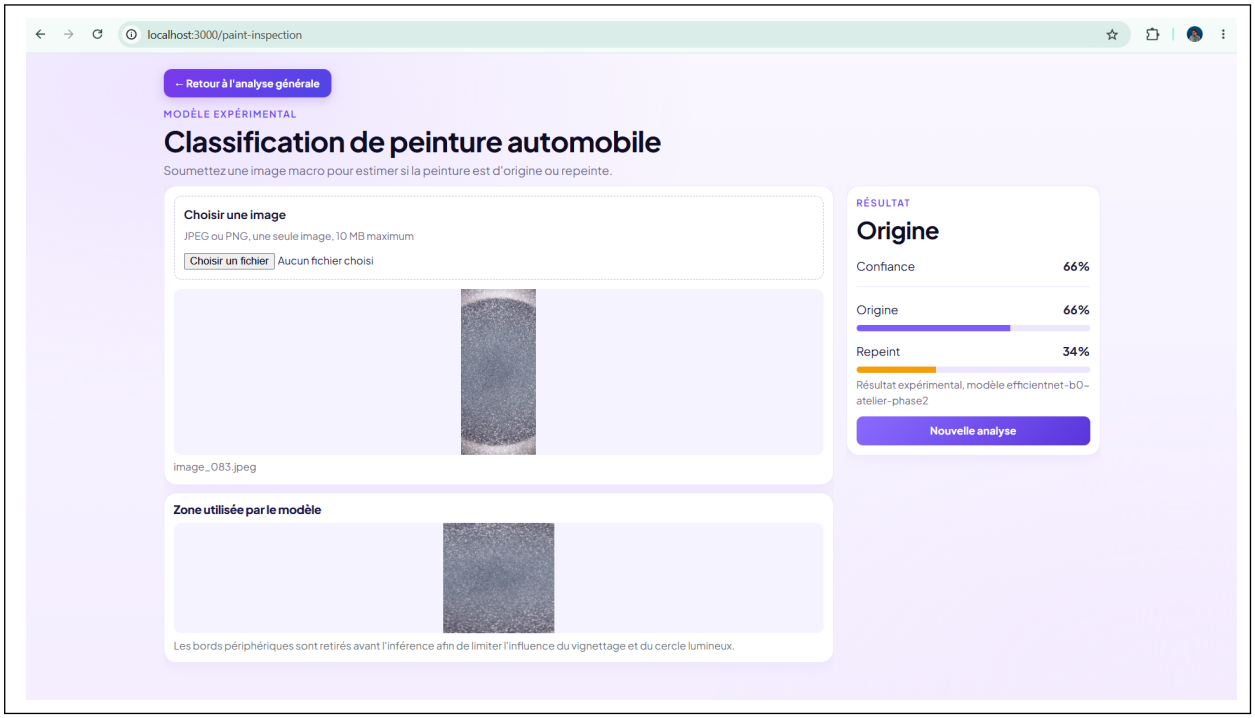


FIGURE 3.5 – Affichage du verdict, des probabilités et de la zone centrale utilisée par le modèle

Dans l'exemple présenté, l'interface indique le verdict produit par le modèle ainsi que son niveau de confiance. Les probabilités associées aux deux classes permettent également de visualiser le degré de séparation obtenu pour l'image analysée.

La visualisation de la zone centrale permet de mieux comprendre le traitement appliqué à l'image et de montrer que les zones périphériques susceptibles de contenir certains artefacts optiques sont réduites lors du prétraitement.

Le résultat présenté par l'interface doit toutefois être considéré comme une sortie expérimentale. Le modèle constitue une preuve de faisabilité et ne remplace pas une expertise automobile ni une validation industrielle définitive.

3.7 DISCUSSION DES RÉSULTATS ET RECOMMANDATIONS

3.7.1 INTERPRÉTATION DES RÉSULTATS

Les résultats montrent qu'un signal visuel et textural peut être exploité à partir des images macro acquises avec le dispositif utilisé.

Le modèle obtient une accuracy de 68,63 % sur le jeu de test et une balanced accuracy de 71,32 %. L'AUC obtenue pour la classe Repeint est de 67,55 %.

Ces résultats suggèrent qu'une capacité de discrimination existe entre les surfaces d'origine et les surfaces repeintes dans les conditions expérimentales étudiées. Cependant, les performances restent insuffisantes pour envisager une utilisation industrielle autonome.

Le rappel de la classe Repeint, égal à 51,72 %, constitue la principale limite. Plusieurs surfaces repeintes sont encore classées comme originaires, ce qui réduit l'intérêt du système pour une détection automatique fiable des repeintes.

Les performances doivent également être interprétées en tenant compte de la taille du dataset, de la variabilité des conditions d'acquisition et des caractéristiques propres aux différentes sessions.

3.7.2 APPORTS ET LIMITES DE L'APPROCHE

L'approche développée dans le cadre de ce stage a permis de mettre en place une première chaîne expérimentale complète pour l'analyse macro-texturale des surfaces automobiles. Elle comprend la définition d'un protocole d'acquisition mobile, l'utilisation d'un matériel accessible composé d'un Redmi Note 12 et d'un module Apexel, ainsi que la constitution d'un dataset propriétaire pilote à partir de captures réalisées dans différents environnements professionnels.

Le travail a également permis de développer un pipeline basé sur EfficientNet-B0, intégrant la préparation des images, la data augmentation, l'entraînement en deux phases, l'évaluation à l'aide de plusieurs indicateurs et l'analyse des erreurs. L'introduction d'un état Incertain permet par ailleurs d'éviter de produire systématiquement un verdict lorsque la confiance du modèle est insuffisante. Enfin, l'intégration du modèle dans une interface web de démonstration facilite la visualisation des prédictions, des probabilités et de la zone centrale utilisée pour l'inférence.

L'approche présente toutefois certaines limites :

- le dataset reste de taille pilote et les classes sont déséquilibrées ;
- les conditions d'acquisition peuvent varier selon l'éclairage, la mise au point, la couleur des surfaces et les caractéristiques des pièces automobiles ;
- le module Apexel peut générer certains artefacts, notamment un vignettage ou un cercle lumineux ;
- le recadrage central permet de limiter l'influence de ces artefacts, sans toutefois les éliminer complètement ;
- la comparaison avec d'autres smartphones n'a pas pu être réalisée en raison du temps disponible pour le stage ;
- Le modèle n'a pas encore été évalué sur un nombre suffisamment important de véhicules indépendants.

Les résultats doivent donc être considérés comme une preuve de faisabilité exploratoire. Ils montrent néanmoins qu'un signal macro-textural potentiellement exploitable est présent

dans les images. Une validation sur un dataset plus large reste nécessaire avant d'envisager une utilisation industrielle autonome.

3.8 CONCLUSION

Ce chapitre a présenté les résultats obtenus avec le pipeline de classification de peinture automobile.

Le modèle EfficientNet-B0 entraîné sur le dataset propriétaire pilote atteint une **accuracy de 68,63 %**, une **balanced accuracy de 71,32 %** et un **F1-score macro de 68,32 %**. La classe **Origine** est mieux reconnue que la classe **Repeint**, dont le rappel reste limité à 51,72 %. L'AUC obtenue pour la classe Repeint est de **67,55 %**.

L'analyse de la matrice de confusion montre notamment un nombre important de faux négatifs pour la classe **Repeint**. Les résultats sont également susceptibles d'être influencés par les conditions d'acquisition, les différences entre les sessions, les caractéristiques des surfaces et certains artefacts optiques du dispositif utilisé.

Une stratégie de gestion des prédictions incertaines a été ajoutée afin d'éviter de fournir systématiquement un verdict lorsque la confiance du modèle est insuffisante.

Enfin, une interface web **React** a été développée et connectée au backend **FastAPI** afin de permettre la sélection d'une image, l'affichage du verdict, des probabilités, du niveau de confiance et de la zone centrale utilisée pour l'analyse.

Les résultats suggèrent la faisabilité de l'approche dans les conditions expérimentales étudiées. Toutefois, une collecte plus importante, une meilleure standardisation du protocole et une validation sur des véhicules indépendants seront nécessaires avant d'envisager une utilisation industrielle.

CONCLUSION GÉNÉRALE

Au terme de ce stage réalisé au sein de la société MALLOULINOVA, dans le cadre du projet MALLOULIAUTO, nous avons étudié et développé une approche expérimentale permettant de distinguer les surfaces de peinture automobile d'origine des surfaces repeintes à partir d'images macro acquises à l'aide d'un smartphone associé à un module optique Apexel.

Ce projet nous a permis d'approfondir nos connaissances sur le plan technique, notamment en vision par ordinateur, traitement d'image, Deep Learning, transfer learning et intégration de modèles d'intelligence artificielle dans une plateforme web.

Tout au long de cette expérience, nous avons été confrontés à différents défis, tels que la constitution d'un dataset adapté, la variabilité des conditions d'acquisition, le déséquilibre entre les classes, l'influence possible des artefacts optiques ainsi que l'adaptation du modèle EfficientNet-B0 à la classification des surfaces automobiles. Les résultats obtenus sur le jeu de test montrent un potentiel de classification, mais les performances restent insuffisantes pour envisager une utilisation industrielle à ce stade.

Ce projet ouvre également la voie à plusieurs perspectives d'amélioration :

- **Enrichissement du dataset** avec un nombre plus important de véhicules, de pièces et de conditions d'acquisition ;
- **Standardisation du protocole de capture** afin de réduire les variations liées à l'éclairage, à la mise au point et au dispositif utilisé ;
- **Validation sur des véhicules non vus lors de l'entraînement** afin de mieux évaluer la capacité de généralisation du modèle ;

- **Amélioration de la détection des surfaces repeintes**, notamment par l'étude de stratégies permettant de réduire les faux négatifs ;
- **Agrégation de plusieurs images d'une même zone** afin d'obtenir une décision mais plus robuste ;
- **Après une validation plus complète, intégration du modèle dans une application mobile** et étude d'une éventuelle conversion vers TensorFlow Lite.

Ainsi, ce stage a constitué une expérience enrichissante sur les plans techniques et professionnels. Il nous a permis de mettre en œuvre une démarche complète, allant de l'acquisition des données jusqu'à l'intégration d'un modèle de Deep Learning dans une plateforme web, tout en constituant une base pour de futurs travaux dans le domaine de la vision par ordinateur et de l'intelligence artificielle appliquée à l'inspection automobile.

BIBLIOGRAPHIE

MICRO-EPSILON. *reflectCONTROL Automotive — Defect Detection on Painted Car Bodies*. Disponible sur : https://www.micro-epsilon.com/measuring-systems/automotive-industry/defect-detection-painted-car-bodies

ISRA VISION. *Car Paint Vision — Detection and Classification of Paint Defects on Car Body Surfaces*. Disponible sur : https://www.isravision.com/en-en/products/carpaintvision

APEXEL. *MS002 — Mobile Phone 200X LED Microscope Lens*. Disponible sur : https://www.shopapexel.com/products/new-mobile-200x-microscope-led-lens

KERAS. *EfficientNet Models — EfficientNetB0*. Keras 3 API Documentation. Disponible sur : https://keras.io/api/applications/efficientnet/efficientnet_models/

TENSORFLOW. *Transfer Learning and Fine-Tuning*. Documentation TensorFlow — Transfer Learning. Disponible sur : https://www.tensorflow.org/guide/keras/transfer_learning

KAGGLE. *Kaggle — Datasets and Machine Learning Projects*. Disponible sur : https://www.kaggle.com/

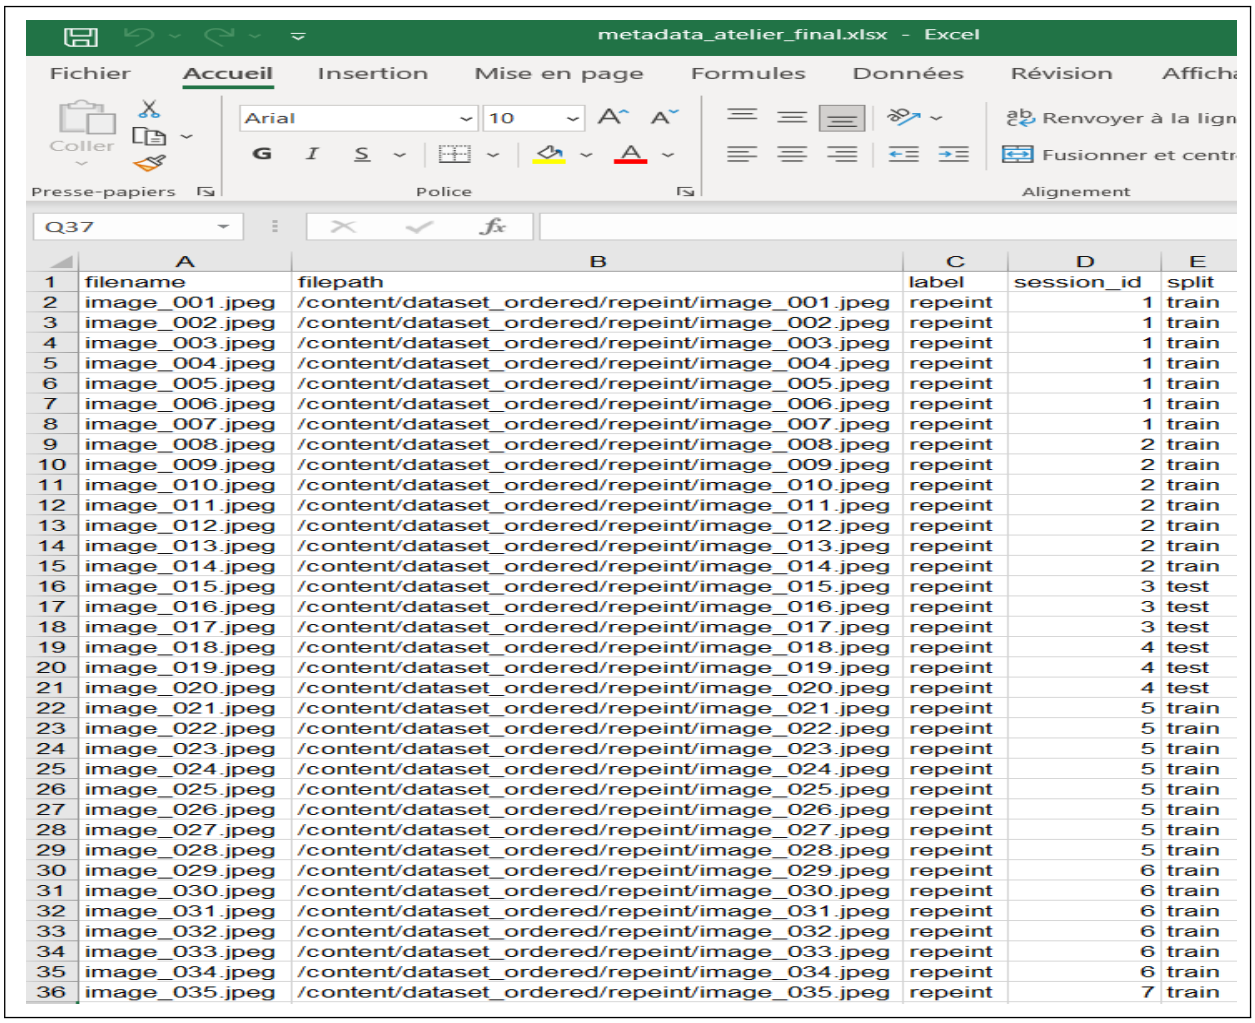
ROBOFLOW. *Roboflow Universe — Computer Vision Datasets and Models*. Disponible sur : https://universe.roboflow.com/

MALLOULINOVA. *Auto-Inspection-Platform — Dépôt GitHub du projet MALLOULIAUTO*. 2026. Disponible sur : https://github.com/Malloulinova/auto-inspection-platform

ANNEXES

A.1 Métadonnées

Le fichier de métadonnées regroupe les informations associées à chaque image, notamment son nom, son chemin d'accès, sa classe, sa session d'acquisition et son appartenance aux ensembles d'entraînement ou de test.



	A	B	C	D	E
1	filename	filepath	label	session_id	split
2	image_001.jpeg	/content/dataset_ordered/repeint/image_001.jpeg	repeint	1	train
3	image_002.jpeg	/content/dataset_ordered/repeint/image_002.jpeg	repeint	1	train
4	image_003.jpeg	/content/dataset_ordered/repeint/image_003.jpeg	repeint	1	train
5	image_004.jpeg	/content/dataset_ordered/repeint/image_004.jpeg	repeint	1	train
6	image_005.jpeg	/content/dataset_ordered/repeint/image_005.jpeg	repeint	1	train
7	image_006.jpeg	/content/dataset_ordered/repeint/image_006.jpeg	repeint	1	train
8	image_007.jpeg	/content/dataset_ordered/repeint/image_007.jpeg	repeint	1	train
9	image_008.jpeg	/content/dataset_ordered/repeint/image_008.jpeg	repeint	2	train
10	image_009.jpeg	/content/dataset_ordered/repeint/image_009.jpeg	repeint	2	train
11	image_010.jpeg	/content/dataset_ordered/repeint/image_010.jpeg	repeint	2	train
12	image_011.jpeg	/content/dataset_ordered/repeint/image_011.jpeg	repeint	2	train
13	image_012.jpeg	/content/dataset_ordered/repeint/image_012.jpeg	repeint	2	train
14	image_013.jpeg	/content/dataset_ordered/repeint/image_013.jpeg	repeint	2	train
15	image_014.jpeg	/content/dataset_ordered/repeint/image_014.jpeg	repeint	2	train
16	image_015.jpeg	/content/dataset_ordered/repeint/image_015.jpeg	repeint	3	test
17	image_016.jpeg	/content/dataset_ordered/repeint/image_016.jpeg	repeint	3	test
18	image_017.jpeg	/content/dataset_ordered/repeint/image_017.jpeg	repeint	3	test
19	image_018.jpeg	/content/dataset_ordered/repeint/image_018.jpeg	repeint	4	test
20	image_019.jpeg	/content/dataset_ordered/repeint/image_019.jpeg	repeint	4	test
21	image_020.jpeg	/content/dataset_ordered/repeint/image_020.jpeg	repeint	4	test
22	image_021.jpeg	/content/dataset_ordered/repeint/image_021.jpeg	repeint	5	train
23	image_022.jpeg	/content/dataset_ordered/repeint/image_022.jpeg	repeint	5	train
24	image_023.jpeg	/content/dataset_ordered/repeint/image_023.jpeg	repeint	5	train
25	image_024.jpeg	/content/dataset_ordered/repeint/image_024.jpeg	repeint	5	train
26	image_025.jpeg	/content/dataset_ordered/repeint/image_025.jpeg	repeint	5	train
27	image_026.jpeg	/content/dataset_ordered/repeint/image_026.jpeg	repeint	5	train
28	image_027.jpeg	/content/dataset_ordered/repeint/image_027.jpeg	repeint	5	train
29	image_028.jpeg	/content/dataset_ordered/repeint/image_028.jpeg	repeint	5	train
30	image_029.jpeg	/content/dataset_ordered/repeint/image_029.jpeg	repeint	6	train
31	image_030.jpeg	/content/dataset_ordered/repeint/image_030.jpeg	repeint	6	train
32	image_031.jpeg	/content/dataset_ordered/repeint/image_031.jpeg	repeint	6	train
33	image_032.jpeg	/content/dataset_ordered/repeint/image_032.jpeg	repeint	6	train
34	image_033.jpeg	/content/dataset_ordered/repeint/image_033.jpeg	repeint	6	train
35	image_034.jpeg	/content/dataset_ordered/repeint/image_034.jpeg	repeint	6	train
36	image_035.jpeg	/content/dataset_ordered/repeint/image_035.jpeg	repeint	7	train

FIGURE A.1 – Métadonnées utilisées pour le dataset

A.2 Configuration et évaluation du modèle

A.2.1 Configuration d'entraînement

TABLE 4 – Configuration d'entraînement du modèle

Paramètre	**Valeur**
Modèle	EfficientNet-B0
Input	$384 \times 384 \times 3$
Classes	Origine / Repeint
Batch size	8
Learning rate Phase 1	1e-3
Learning rate Phase 2	1e-5
Fine-tuning	5 dernières couches
Crop	32 pixels par côté
Class weighting	Oui
Data augmentation	Train uniquement
Seuil Repeint	0,52
Seuil Incertain	0,65

A.2.2 Classification report

TABLE 5 – Classification report du modèle

Classe	**Precision**	**Recall**	**F1-score**	**Support**
Origine	0,588	0,909	0,714	22
Repeint	0,882	0,517	0,652	29
Macro average	**0,735**	**0,713**	**0,683**	**51**